INSTITUTO FEDERAL
Brasília

Instituto Federal de Brasília
Bacharelado em Ciência da Computação
Campus Taguatinga
http://computacaoifb.com

IDENTIFICAÇÃO DE INSETOS-PRAGA DA CULTURA DE SOJA COM VISÃO COMPUTACIONAL

Por

RAQUEL PINHEIRO DA COSTA

Trabalho de Graduação

BRASÍLIA-DF/2022

Raquel Pinheiro da Costa

IDENTIFICAÇÃO DE INSETOS-PRAGA DA CULTURA DE SOJA COM VISÃO COMPUTACIONAL

Trabalho apresentado ao Programa de Bacharelado em Ciência da Computação do da Instituto Federal de Brasília como requisito parcial para obtenção do grau de Bacharel em Ciência da Computação.

Orientador: João Victor de Araujo Oliveira
Co-Orientadora: Luciane Modenez Saldivar Xavier

BRASÍLIA-DF
2022

Costa, Raquel Pinheiro da
Identificação de insetos-praga da cultura de soja com visão computacional/ Raquel Pinheiro da Costa . – BRASÍLIA-DF, 2022.
56 f. : il.

Monografia (Bacharel em Ciência da Computação) – Instituto Federal de Brasília – Campus Taguatinga, 2022.

Orientador : João Victor de Araujo Oliveira.
Co-Orientadora : Luciane Modenez Saldivar Xavier.

Inclui referências.

1. Rede de computadores. 2. Redes neurais (Computação). 3. Tecnologia da informação. 4. Soja - Cultivo. 5. Soja - Doenças e pragas. I. Identificação de insetos-praga da cultura de soja com visão computacional. II. Oliveira, João Victor de Araújo. II. Xavier, Luciane Modenez Saldivar. III.Instituto Federal de Educação, Ciência e Tecnologia de Brasília.

CDU 004.7:633.34

Trabalho de Graduação apresentada por **Raquel Pinheiro da Costa** ao programa de Graduação em Ciência da Computação do Instituto Federal de Brasília, sob o título **Identificação de insetos-praga da cultura de soja com visão computacional**, orientado pelo **Prof. MSc. João Victor de Araujo Oliveira** e aprovada pela banca examinadora formada pelos professores:

_____ -

Prof. Dr. Daniel Saad Nogueira Nunes
IFB/Taguatinga

_____

Prof. Dr. Raimundo Cláudio da Silva Vasconcelos
IFB/Taguatinga

BRASÍLIA-DF
2022

Dedico este trabalho primeiramente a Deus, sem ele nada seria possível, a minha família e meu namorado por todo o carinho, apoio e aos meus orientadores que me auxiliaram durante todo o processo de desenvolvimento deste projeto.

Resumo

Palavras-chave: Rede neural convolucional, *Alexnet*, cultura da soja.

O Brasil é um grande produtor de grãos sendo o maior produtor de soja do mundo, mas todo esse crescimento na produção de soja no país só foi possível graças aos avanços científicos e tecnológicos, como o desenvolvimento de técnicas de manejo de solo, manejo de adubação e o manejo de pragas e doenças. Atualmente, o manejo de insetos-pragas da soja é realizado com a utilização do Manejo Integrado de Pragas (MIP) que tem como principal objetivo auxiliar nas tomadas de decisão quanto o manejo de insetos-praga. Apesar de se mostrar muito eficiente algumas de suas técnicas podem demandar tempo e recursos humanos como é o caso da técnica de monitoramento com o uso do pano de batida. Neste sentido o presente trabalho buscou de auxiliar na automação desse processo de identificação de pragas e conduziu experimentos com a utilização de técnicas de visão computacional para realizar a classificação com redes neurais convolucionais (*ALEXNET*) e dois diferentes conjuntos de imagens, avaliando o impacto da adição de inimigos naturais a um dos conjuntos. A maior taxa de classificação foi de 91% para o conjunto de imagens contendo os inimigos naturais. O resultado das comparações entre os dois experimentos não exibiram diferenças consideráveis, entretanto a rede neural implementada obteve êxito em sua taxa de classificação.

Abstract

Keywords: Convolutional neural network, *Alexnet*, soybean crop.

Brazil is a large grain country, being the largest soybean producer in the world (CONAB, 2021), but all this growth in soybean production in the country was only possible thanks to scientific and technological advances, such as the development of soil management techniques , fertilization management and pest and disease management. Currently The management of insect pests in soybean is carried out with the use of Integrated Pest Management (IPM) which has as main objective to help with the decision regarding the management of insect pests, although it is very efficient, its techniques may require time and human resources, as is the case with the batting cloth. In this sense, automation in the search to assist in the identification process of technical tests, experiments with the use of computer vision to perform the classification with convolutional neural networks (ALEXNET) and evaluating sets of images, two different impact of the addition of natural enemies to a of the sets. The highest classification rate was 91% for the set of images containing natural enemies. The result does not present comparisons between the two presented results, however the network obtained neural results of the two considered classifications.

Lista de Figuras

2.1 Diagrama das etapas do processamento de imagens. 22
2.2 Exemplo da aplicação de filtros de média e mediana 24
2.3 Binarização 25
2.4 Exemplo de uma CNN. 27
2.5 Esquema de construção das camadas rede neural. 28

3.1 Utilização do pano de batida. 31
3.2 Ciclo de vida : *Nezara viridula*. 32
3.3 Ciclo de vida : *Euschistus heros*. 33
3.4 Ciclo de vida : *Piezodorus guildinii*. 34
3.5 Exemplo de uma Tesourinha 35
3.6 Exemplo de um Crisopídeos 35
3.7 Exemplo de Joaninha 35

5.1 Diagrama das Etapas Realizadas no Projeto. 41
5.2 Exemplo de Pré-Processamento. 44

Lista de Tabelas

3.1 Tabela de insetos-praga que causam danos nas lavouras de soja. 30

4.1 Resumo da Revisão de Literatura 40

5.1 Composição do Conjunto Positivo experimento com inimigos naturais 42
5.2 Composição do Conjunto Negativo experimento com inimigos naturais 43
5.3 Composição do Conjunto Negativo experimento sem inimigos naturais 43

6.1 Resumo dos Resultados dos experimentos 1 e 2 48

Lista de Acrônimos

MIP Manejo Integrado de Pragas 19

MIT Massachusetts Institute of Technology 21

GPUS Graphics Processing Unit 21

PCA Análise de Componentes Principais 26

RNA Redes Neurais Artificiais 26

CNNs Redes Neurais Convolucionais 26

NDE Nível de Dano Econômico 30

Sumário

1 Introdução **19**

1.1 Objetivos 20

1.1.1 Objetivo Geral 20

1.1.2 Objetivos Específicos 20

1.2 Descrição dos Capítulos Seguintes 20

2 Fundamentação Teórica **21**

2.1 Definição de Visão Computacional 21

2.2 Processamento de Imagens 22

2.2.1 Aquisição da imagem 23

2.2.2 Aumento do Conjunto de Imagens 23

2.2.3 Pré-Processamento 23

2.2.4 Segmentação 24

2.2.5 Extração de Características 25

2.2.6 Classificação 26

2.3 *Deep Learning* 26

2.3.1 Arquiteura *ALEXNET* 27

2.3.2 Funções de ativação 27

3 A Cultura da Soja **29**

3.1 Insetos-praga da Cultura da Soja 29

3.1.1 *Nezara viridula* 32

3.1.2 *Euschistus heros* 33

3.1.3 *Piezodorus guildinii* 33

3.2 Inimigos Naturais 34

3.2.1 "Tesourinhas" (Dermaptera: Forficulidae) 34

3.2.2 "Crisopídeos" (Neuroptera: Chrysopidae) 34

3.2.3 "Joaninhas" (Coleoptera: Coccinelidae) 35

4 Revisão de Literatura **37**

5 Projeto **41**

5.1 Considerações sobre o Método de Visão Computacional proposto no projeto. . 42

5.2 Criação dos Conjuntos de Dados 42

5.3 Pré-Processamento 43

5.4 Classificação com inimigos naturais 44

5.5 Classificação sem inimigos naturais 44

6 Resultados e Discussão **47**
6.1 Experimentos 47
6.2 Discussão dos resultados 47

7 Conclusões **49**

Referências **51**

1
Introdução

A soja *Glycine max* (L.) Merrill,1917 (Fabales: Fabaceae) é o grão mais cultivado no Brasil, além de ser uma das culturas de maior importância na economia mundial. O aumento de sua produção está estritamente relacionado a investimentos em tecnologias ligadas ao setor produtivo e ao desenvolvimento de tecnologias relativas à adubação e ao manejo de solo e de insetos-praga. Além de questões relacionadas à identificação e solução das principais questões responsáveis pelas perdas durante as colheitas (FREITAS, 2011).

A monocultura da soja vem sofrendo com ataques de insetos-praga durante todo ciclo produtivo, sendo esse o fator que gera uma das maiores limitações na produção. Dentre os principais insetos-praga no cultivo da soja, destacam-se percevejos como *Nezara viridula*, *Piezodorus guildinii* e *Euschistus heros* uma vez que se alimentam dos grãos e afetam consideravelmente o rendimento e qualidade do cultivo (FREITAS, 2011).

Atualmente, o controle de insetos-praga em agroecossistemas é realizado com base no Manejo Integrado de Pragas Manejo Integrado de Pragas (MIP), que permite que decisões de controle sejam tomadas de acordo com o nível de dano, nível populacional e a espécie de insetos-praga, considerando também o estágio de desenvolvimento da monocultura de soja. Este processo de monitoramento de insetos-praga deve ser realizado em tempo real e exige recursos humanos capacitados e materiais. Apesar de se mostrar um método eficiente, o processo para quantificar e qualificar os insetos-praga, a campo, pode ser demorado, o que dificulta a avaliação no monitoramento desses insetos (CORRÊA-FERREIRA, 2012).

Diante do exposto, é relevante o desenvolvimento de tecnologias que possam auxiliar na detecção de insetos-praga, a fim de que as devidas estratégias de manejo possam ser definidas em tempo hábil. Nesse contexto, várias pesquisas foram realizadas a fim de auxiliar a automatização do processo de identificação de insetos-praga com o uso visão computacional (KRISHNA, 2017; VOULODIMOS et al., 2018; SILVA et al., 2019; TIAN et al., 2020). No entanto, esses estudos não consideram a presença de seus inimigos naturais nas lavouras, que poderiam ser inseridos no conjunto negativo. Assim, o presente trabalho buscou responder se a utilização dos inimigos naturais no conjunto negativo é capaz de tornar o método de identificação de insetos-praga mais robusto.

1.1 Objetivos

1.1.1 Objetivo Geral

O presente trabalho teve por objetivo desenvolver um método de identificação de insetos-praga da cultura da soja, com o uso de métodos de visão computacional.

1.1.2 Objetivos Específicos

- Criar um conjunto positivo de imagem de três entre os principais percevejos considerados insetos-praga da soja.
- Criar um conjunto negativo de imagens com três inimigos naturais de insetos-praga presentes na cultura da soja, além de imagens onde não há presença de insetos em folhagem de soja;
- Realizar a etapa de pré-processamento nos conjuntos de imagens negativas e positivas;
- Realizar a etapa de classificação com a construção de um modelo de rede neural supervisionada para a identificação de insetos-praga;
- Realizar uma análise comparativa, ao avaliar o impacto da adição dos inimigos naturais no conjunto negativo.

1.2 Descrição dos Capítulos Seguintes

O presente trabalho foi dividido em sete capítulos. No Capítulo 2 foram abordados os principais conceitos de Visão Computacional, desde sua definição, métodos de processamento de imagens e aplicações de *Deep learning* em imagens. No Capítulo 3 foram apresentadas informações sobre a cultura da soja, seus insetos-praga e inimigos naturais de interesse nesse projeto. No Capítulo 4 foi realizada uma revisão de literatura com foco em artigos científicos que utilizaram técnicas de Visão Computacional para a identificação de insetos-praga. No Capítulo 5 foram descritos os passos para a realização do projeto. No Capítulo 6 foram realizada uma discussão a repeito dos resultados encontrados. Finalmente no Capítulo 7 encontram-se as conclusões.

2

Fundamentação Teórica

2.1 Definição de Visão Computacional

De acordo com KRISHNA (2017) há duas maneiras de definir a Visão Computacional, a primeira destaca que é a ciência que busca extrair diferentes informações de imagens digitais. A segunda enfatiza que a Visão Computacional consiste em elaborar algoritmos que buscam compreender o conteúdo de imagens a fim de usá-lo em uma aplicação. Sendo assim, a Visão Computacional é responsável pela maneira como as máquinas enxergam o mundo, fazendo a extração de informações que permitem reconhecer e manipular os objetos na imagem. SZELISKI (2010), diretor fundador do grupo de Fotografia Computacional do *Facebook*, relatou que a Visão Computacional teve início por volta de 1970, com o principal objetivo de criar robôs dotados com inteligência humana. Os precursores dessa época, o *Massachusetts Institute of Technology (Massachusetts Institute of Technology (MIT))* e a Universidade de *Stanford*, julgaram que trabalhar com entradas visuais seria uma tarefa fácil, resolvida em pouco tempo, e que conduziria a encontrar soluções para problemas mais difíceis.

Por volta de 1976, foram surgindo aplicações diferentes do processamento de imagens como deduzir a estrutura de objetos 3D e detecção de bordas. Em 1980, a atenção foi voltada para a matemática, ao desenvolver análises quantitativas de imagens, e notou-se que algoritmos de detecção estéreo, formas, e bordas poderiam ser descritos igualmente graças a utilização de regularização. Nos anos de 1990 já haviam sistemas de modelagem 3D totalmente automatizados, as técnicas de aprendizagem estatísticas começam a gerar sistemas de rastreamento mais sofisticados e a computação gráfica começou a ganhar destaque.

Nos anos 2000, ocorreu expressiva explosão na Visão Computacional. Com o aumento do poder computacional e a quantidade de dados disponíveis, que começaram a surgir e geraram relevantes mudanças. Atualmente, técnicas de aprendizado de máquina (*Machine Learning*), mais complexas, são aplicadas em uma ampla quantidade de dados para o reconhecimento de objetos que, juntamente com técnicas de *deep learning*, Graphics Processing Unit (GPUS) e modelos de redes neurais, geraram um acelerado avanço no reconhecimento de imagens.

2.2 Processamento de Imagens

O processamento de imagens é um conjunto de técnicas computacionais que buscam extrair informações a partir de imagens, realizando a análise e a manipulação de imagens com auxílio do computador. Seu principal objetivo é melhorar a qualidade de impressão de imagens digitais. Nos anos de 1960, graças a computadores digitais, o processamento de imagens passou a ser utilizado para diferentes aplicações, e atualmente, continuam a crescer a quantidade de aplicações diversas que podem ser realizadas com uso das técnicas que compõem essa área (FILHO; NETO, 1999).

Um sistema de processamento de imagens é divididos em várias etapas, sendo aquisição, pré-processamento, segmentação, extração de característica e classificação das etapas mais comumente encontradas na literatura, demonstrado na Figura 2.1 (RIBEIRO, 2015; ALBUQUERQUE FILHO; ALBUQUERQUE NETO, 2003; ROSA, 2018).

Figura 2.1: Diagrama das etapas do processamento de imagens

A seguir são descritos com maiores detalhes cada uma das etapas do processamento de imagem.

2.2.1 Aquisição da imagem

A aquisição das imagens é a primeira etapa do processamento. Nela as imagens são obtidas de acordo com a necessidade da pesquisa (FILHO; NETO, 1999) e essa aquisição necessita de dois elementos básicos, um sensor e um digitalizador. Esse sensor é responsável por converter o dado óptico em um sinal elétrico, enquanto o digitalizador realiza a conversão da imagem analógica em imagem digital. Nesse processo as condições climáticas, as condições de iluminação, a resolução, o nível de cinza da imagem e, até mesmo a escolha do tipo de sensor ou lente escolhida, são importantes influenciadores no resultado final.

2.2.2 Aumento do Conjunto de Imagens

O aumento do conjunto de Imagens se mostrou eficaz desde de suas primeira demostrações como deslocamentos horizontais, cortes aleatórios e aumento no espaço de cores (SHORTEN; KHOSHGOFTAAR, 2019). Existem diferentes algoritmos para realização do aumento, na presente pesquisa enfatizou-se as transformações geométricas. Dentre as principais transformações geométricas destacam-se:

- Giro: essa transformação consistem em realizar uma giro horizontal ou vertical na imagem, considerado um aumento simples de ser implementado e considerado eficaz em conjuntos de imagem como o ImageNet (SHORTEN; KHOSHGOFTAAR, 2019);
- Rotação: a rotação consistem em girar a imagem em um eixo entre 1º e 359º (SHORTEN; KHOSHGOFTAAR, 2019); e
- Transformação: consiste em deslocar a imagem para a esquerda ou direita, para cima ou para baixo (SHORTEN; KHOSHGOFTAAR, 2019).

2.2.3 Pré-Processamento

O pré-processamento tem como principal objetivo otimizar a qualidade das imagens adquiridas. Existem diversas técnicas que podem ser utilizadas nessa etapa. Existem ainda duas importantes classes que devem ser abordadas. A primeira classe contém as técnicas de domínio espacial, nesta são utilizadas filtros para manipular as imagens. Na segunda classe estão as técnicas que trabalham com a frequência da imagem, onde também é feita a utilização de filtros, mas tratando o espectro da frequência das imagens. A escolha das técnicas utilizadas depende do que se pretende destacar nas imagens, porém, na maioria das vezes, é utilizada uma combinação de diferentes técnicas que estão intimamente ligadas com as duas classes descritas anteriormente. Na Figura 2.2 é possível observar um exemplo da aplicação de filtros de média e mediana para suavizar a imagem. O filtro da média com ordem N realiza a média aritmética dos valores de N *pixels* vizinhos a cada iteração da convolução, essa média produzida resulta no valor dos

pixels processados. Assim, a suavização resultante depende das dimensões das máscara utilizada, quanto maior a máscara utilizada, mais forte é suavização (QUEIROZ; GOMES, 2006).

Figura 2.2: Filtros da média e mediana: (A) imagem original; (B) aplicação de um filtro de média; (C) aplicação de um filtro de mediana.

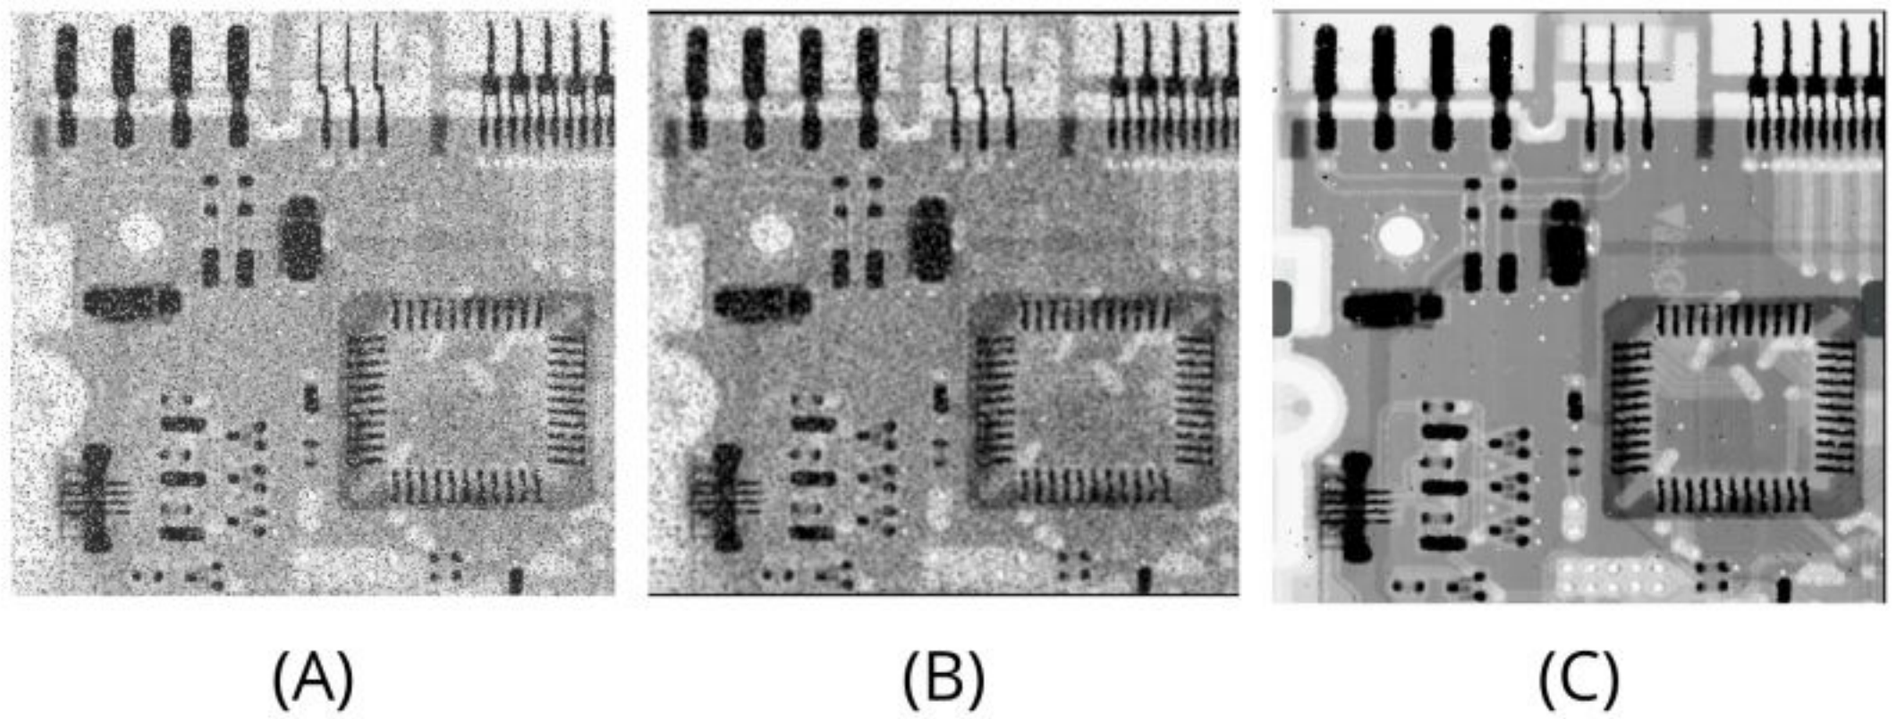

Fonte: FARIA (2015)

Outra técnica que trabalha a primeira classe, principalmente quanto ao domínio espacial, é o Aumento de Imagem (*Image augmentation*) sua principal utilização ocorre quando o conjunto de imagens adquiridos é menor, mas a sua utilização pode ser realizada em busca de alcançar melhora na precisão do modelo. Essa técnica consiste em realizar o redimensionamento das imagens, rotações, inversões e cortes a fim de tornar o conjunto de imagens mais generalizado (KASINATHAN et al., 2020).

2.2.4 Segmentação

A segmentação consiste na separação da imagem por partes. Grupos de *pixels* são divididos e comumente classificados como objetos e fundos. Nesta etapa, a imagem é dividida, de acordo com as regiões de interesse, para a análise e utilização da mesma nas etapas posteriores. Sendo assim, a etapa atual requer atenção especial, visto que qualquer erro cometido causará consequências nas etapas seguintes e no resultado final.

Existem diferentes técnicas que podem ser utilizadas no processo de segmentação. Apesar disso, não existe um padrão para o processo ser realizado. Dessa forma, as necessidades e condições das imagens devem ser consideradas para definir como esse processo será realizado. Quanto às técnicas, existem duas óticas fundamentais, a primeira ótica diz respeito a similaridade entre *pixels*, sendo a técnica mais utilizada de similaridade como, por exemplo, a técnica de binarização. Nesta técnica, os níveis de cinza da imagem devem ser usados como limiar para realizar a separação entre o fundo, os *pixels* e os objetos presentes na imagem, e então é gerado uma saída binária com níveis de iluminação de branco e preto. Em contrapartida, a segunda ótica diz respeito à descontinuidade entre *pixels*. Nesta, o objetivo principal é determinar as variações de iluminação entre *pixels* que estejam lado a lado, definindo grupos de *pixels* para

encontrar os contornos e bordas dos objetos presentes na imagem (ALBUQUERQUE FILHO; ALBUQUERQUE NETO, 2003). Na Figura 2.3 foram apresentados exemplos de segmentação.

Figura 2.3: Duas abordagens para segmentação. (A) Imagem original em níveis de cinza. (B) Imagem segmentada através de uma binarização. (C) Imagem segmentada por detecção de bordas.

Fonte: ALBUQUERQUE FILHO; ALBUQUERQUE NETO (2003)

2.2.5 Extração de Características

OLIVEIRA (1997), destacou que a extração de características possui como objetivo principal, fazer a seleção de características importantes que possam ajudar a dividir os objetos de uma imagem em diferentes classes. Sendo assim, este processo pode ser considerado como um dos principais aspectos em um sistema de Visão Computacional, pois é responsável por fornecer as informações necessárias que levarão a uma divisão de características da imagem, de forma que melhor contribua para o resultado final. As informações obtidas na imagem são representadas em pontos de interesse, sendo essas informações relevantes para a classificação.

As características extraídas de uma imagem podem ser classificadas em três tipos básicos (JAIN et al., 1995), características globais que são descrições que utilizam todos os pontos de uma área da imagem. Perímetros, características globais, características locais são calculadas com base no contorno de um objeto ou de uma pequena área da imagem. As características relacionais são descrições que utilizam pontos locais e diferentes como contorno e concavidades locais.

Para encontrar os pontos de interesse podem ser utilizados algoritmos como o *SIFT* e o *SURF* (SILVA et al., 2015). No primeiro, cada ponto de interesse corresponde a um local extremo do filtro, da diferença Gaussiana e é descrito em um vetor de características de 128 dimensões. O segundo algoritmo, citado acima, é amplamente utilizado em reconhecimento de objetos, pois lida com o determinante da aproximação da matriz Hessiana para detectar os pontos de interesse. Assim, os dois algoritmos são capazes de delimitar uma região em volta do ponto de interesse,

adicionando uma orientação definida pelo cálculo de resposta da região a um filtro (SILVA et al., 2015). Existem diversas outras técnicas de extração de características. Duas com grande destaque são a Análise de Componentes Principais (PCA) que consiste em dadas N variáveis e procura-se encontrar combinações lineares para produzir índices não correlacionados e a outra são as arquiteturas de Redes Neurais Artificiais (RNA). Além de algoritmos que implementam métodos estatísticos que possuem vantagens em relação ao métodos clássicos por serem mais adaptativos e oferecerem a generalização para novos dados (OLIVEIRA, 1997).

2.2.6 Classificação

Na classificação, o maior objetivo é rotular os objetos a partir de suas características. De acordo com ALBUQUERQUE FILHO; ALBUQUERQUE NETO (2003) a etapa de classificação é dividida em duas partes, o aprendizado e o reconhecimento. Segundo esses autores os sistemas de reconhecimento de formas são utilizados as informações adquiridas na etapa de extração a fim de montar um espaço com N dimensões. Assim, os sistemas de aprendizado são responsáveis por encontrar uma função que realize a separação das formas contidas no espaço, alguns fatores como a escolha de qualidade dos parâmetros são relevantes para um eficiente reconhecimento da forma. No caso de serem escolhidos poucos parâmetros de medida podem ser gerados erros no reconhecimento, caso seja escolhido, um grande número de parâmetros o espaço torna-se grande dificultando o aprendizado.

2.3 *Deep Learning*

Segundo VOULODIMOS et al. (2018), o *Deep learning* consiste num conjunto de técnicas que incluem diferentes algoritmos, de aprendizagem supervisionadas e não supervisionadas, sendo possível criar modelos computacionais com diferentes camadas e níveis de abstração. Na busca de imitar a maneira como o cérebro humano compreende as informações. Fatores como grande conjuntos de dados rotulados, novas técnicas de regularização e surgimento de frameworks como *Theano* e TensorFlow, para criar modelagens de forma mais eficiente, contribuíram para o um grande destaque do *Deep learning*. Esse conjunto de técnicas, trouxe relevantes avanços para diversos problemas de Visão Computacional como, por exemplo, a detecção de objetos e rastreamento de movimentos.

No *Deep Learning* são utilizados modelos que possuem várias camadas de processamento que aprendem as características dos dados, dentre eles são as Redes Neurais Convolucionais (CNNs).

CNNs são um tipo de rede neural que possuem várias camadas projetadas com o objetivo de reconhecer padrões visuais encontrados em imagens de *pixels* pré-processadas (KRIZHEVSKY et al., 2012). Esse tipo de arquitetura utiliza um extrator de recursos e um classificador treinado de ponta a ponta. Esse extrator é composto de várias camadas convolucionais e de *pooling* sendo as camadas convolucionais responsáveis por realizar convoluções

ponderadas entre as entradas e os pesos atribuído a elas e encontrando padrões, enquanto as camadas de *pooling* são camadas não treináveis utilizadas para reduzir a dimensão das entradas. O classificador é composto por uma ou mais camadas conectadas e a função *softmax* (NANNI et al., 2020). Na figura 2.4 é possível observar um exemplo de como é composta uma rede neural CNN. A rede recebe uma imagem RGB e possui diferentes camadas até produzir uma saída.

Figura 2.4: Exemplo de uma CNN

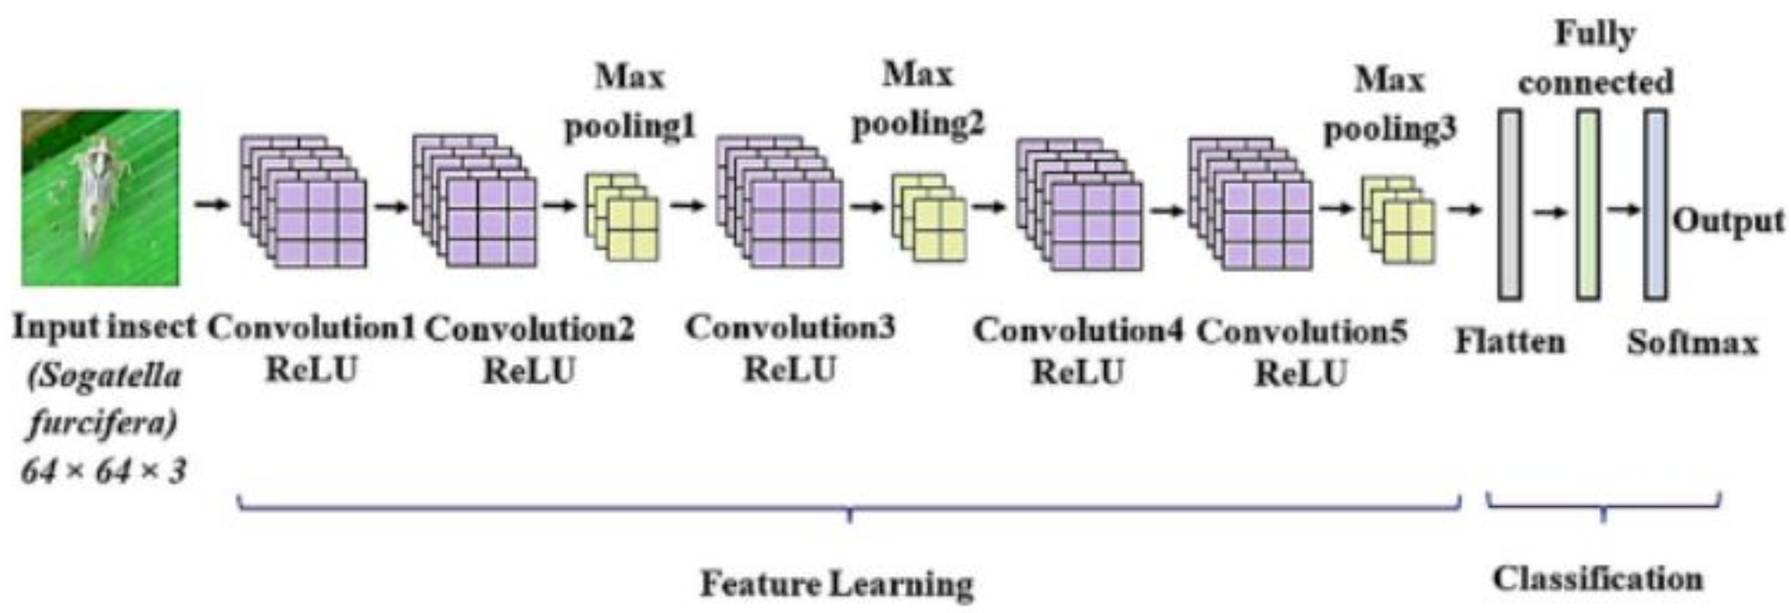

Fonte: KASINATHAN et al. (2020)

2.3.1 Arquiteura *ALEXNET*

A rede neural foi implementada com a utilização da *API Keras Sequential* onde as camada são empilhadas de forma consecutiva. As camadas da *AlexNet* CNN são: (1) Camada de convolução (*Layer*), cujo o termo matemático convolução refere-se ao produto escalar entre dois conjuntos. Dentro da aprendizagem profunda, essa camada é responsável por atuar nos filtros, também chamados de *kernel*, e na matriz de dados dentro da camada de entrada, ou seja, a camada convolucional realiza convoluções entre os filtros e imagens de entrada para uma rede neural convolucional; (2) A Camada de Normalização (*Batch Normalization*) responsável por realizar operações de normalização nas entradas das camadas anteriores; (3) A Camada de *Max Pooling* que passa pelos dados de entrada e calcula a media entre os *pixels* dentro do campo do *Kernel*; (4) A Camada de *Flatten* responsável por nivelar os dados da imagem de entrada em uma matriz unidimensional; (5) A camada de *Dropout* responsável por realizar uma redução aleatória no numero de neurônios (ALAKE, 2020) e (6) A Camada Densa (*Dense*) é a ultima camada da rede onde ocorre classificação, através da utilização da função *softmax* (BASH et al., 2020). Na Figura 2.5 é possível observar a sequência em que as camadas foram implementadas e quantas vezes elas aparecem no modelo (KRIZHEVSKY et al., 2012).

2.3.2 Funções de ativação

As funções de ativação são funções matemáticas cujo o principal objetivo é inserir linearidade na rede, permitindo que a rede neural possua maior poder de representação para

Figura 2.5: Esquema de construção das camadas da arquitetura da rede neural *ALEXNET*

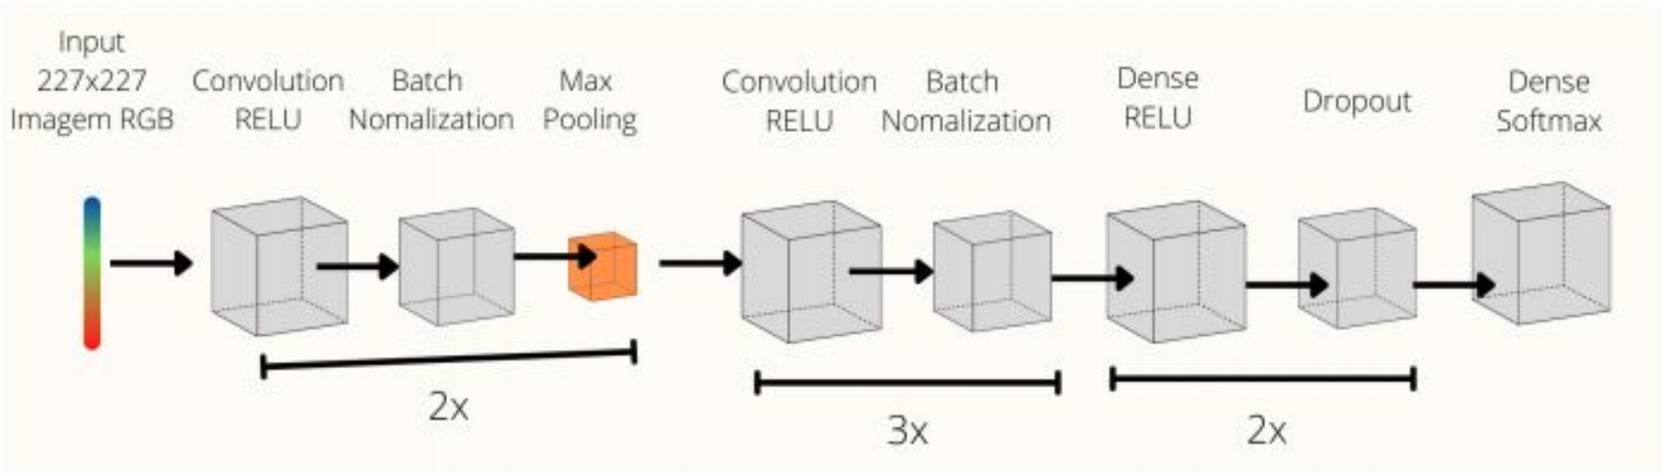

resolver funções complexas. Na implementação da rede foram utilizadas duas funções descritas a seguir:

- Função de Ativação de Unidade Linear Retificada (ReLU): responsável por reduzir os valores de neurônios negativos a 0, enquanto o valores positivos permanecem (ALAKE, 2020); e
- Função de ativação *Softmax*: responsável por retornar um vetor onde o seu conjunto representa a probabilidade da ocorrência de uma classe (ALAKE, 2020).

3
A Cultura da Soja

De acordo com BONATO; VARIANI (1987) a soja *G. max* tem origem no leste da Ásia, região central da China, em aproximadamente 2207 a.C, e pode ser considerada uma das espécies cultivadas mais antigas. Posteriormente, foi introduzida na Coreia e Japão, e em 1739 ocorreu seu primeiro cultivo na Europa. Na América, a soja foi introduzida em 1804, nos Estados Unidos e no Brasil. Em 1970, o aumento no valor financeiro da soja atraiu agricultores e o governo brasileiro. A partir desse período, passou-se a investir em tecnologias e pesquisas para aprimorar o cultivo dessa oleaginosa. De forma a revolucionar a história mundial do cultivo dessa cultura e permitir que, pela primeira vez, um grão fosse plantado com sucesso em baixas latitudes entre os trópicos, com destaque para o Brasil nesse mercado.

Atualmente, segundo a Companhia Nacional de Abastecimento (CONAB, 2021), o Brasil ocupa o primeiro lugar em produção mundial de soja. Com uma produção recorde estimada de cerca de 135,4 milhões de toneladas na safra de 2020/2021, houve um aumento de 4,2% em território plantado, se comparado à safra anterior, alcançando 38,5 milhões de hectares. Em relação à produção, houve um aumento de 8,9% em contraste com a safra passada, na região Centro-Oeste é onde encontra-se a maior parte de área plantada. A partir da soja podem ser extraídos diversos produtos como leite, queijo, farinha, óleo e até biodiesel. O processo de industrialização da soja pode ser dividido em duas partes, na primeira é realizada a produção do óleo bruto, que gera, como resíduo, o farelo de soja. Nesta etapa pode ocorrer também a extração da lecitina, amplamente utilizada na produção de tintas, cosméticos, margarina e cobertura como emulsificante. Na segunda etapa é realizado o refinamento do óleo bruto (GONDIN, 2019).

3.1 Insetos-praga da Cultura da Soja

A cultura da soja é alvo de uma diversidade de insetos-praga. Esses insetos atacam desde a fase de germinação até a colheita, o que compromete a produção ou a qualidade do produto final. Esses insetos podem danificar plântulas (embrião vegetal contido na semente), folhas, flores, vagens e grãos. Na fase de germinação, alguns exemplos de insetos-praga são bicudo-da-soja (*Sternechus subsignatus*), lagarta elasmo (*Elasmopalpus lignosellus*), os corós (*Scarabaeoidea*) e percevejos-castanhos-da-raiz (*Scaptocoris castanea* e *Atarsocoris brachiariae*). Conforme

a planta vai se desenvolvendo outros insetos como lagarta-da-soja (*Anticarsia gemmatalis*), e a lagarta falsa-medideira (*Pseudoplusia includens*) danificam as folhas e flores. Na fase reprodutiva, percevejos como *Nezara viridula*, *Piezodorus guildinii* e *Euschistus heros* causam danos até a fase do desenvolvimento dos grãos. Na Tabela 3.1 é possível observar exemplos de insetos-praga, em que parte das plantas eles atacam e qual a sua importância como praga.

Tabela 3.1: Tabela de insetos pragas que atacam as lavouras de soja

Inseto	Parte da planta atacada	Importância
Anticarsia gemmatalis	Fo[1]	Praga principal
Epinotia aporema	Fo, Br, Va	Secundária, com alguma importância em áreas restritas
Omiodes indicatus	Fo	Secundária, geralmente ocorrendo no final do ciclo da cultura, quando a desfolha não é importante
Pseudoplusia includens	Fo	Secundária
Rachiplusia nu	Fo	Secundária
Cerotoma sp.	Fo(A), No(L)	Secundária, em áreas de soja precedida por feijão
Diabrotica speciosa	Fo(A), Ra(L)	Secundária, em áreas de soja precedida por milho "safrinha"
Aracanthus mourei	Fo, Pe	Secundária, ocorrência no início do crescimento da soja
Maecolaspis calcarifera	Fo	Secundária
Megascelis sp.	Fo	Secundária
Chalcodermus sp.	Fo	Secundária, praga regionalmente importante
Bemisia argentifolii	Fo	Secundária, com potencial alto de dano
Gafanhotos	Fo	Esporádica
Ácaros	Fo	Esporádica
Tripes	Fj	Secundária, importante em áreas muito restritas, vetores de vírus da "queima do broto"
Nezara viridula	Va, Se	Praga principal
Piezodorus guildinii	Va, Se	Praga principal
Euschistus heros	Va, Se	Praga principal
Dichelops furcatus	Va	Secundária
Edessa meditabunda	Va	Secundária
Thyanta perditor	Va	Secundária
Acrosternum sp.	Va	Secundária
Ethiella zinckenella	Va	Secundária, com alguma importância em áreas restritas
Spodoptera latifascia	Va	Esporádica
Spodoptera eridania	Va	Esporádica
Maruca testulalis	Va	Esporádica
Sternechus subsignatus	Ha	Praga regionalmente importante
Elasmopalpus lignosellus	Ha	Esporádica, usualmente importantes em anos com prolongado período seco, na fase inicial da cultura
Myochrous armatus	Ha	Esporádica
Blapstinus sp.	Pl, Ha	Esporádica
Piolhos-de-cobra	Pl, Pp	Secundária, importante em áreas de semeadura direta
Caracóis e lesmas	Pl, Co, Fj	Secundária, importantes em áreas de semeadura direta
Phyllophaga spp. (Corós)	Ra	Praga regionalmente importante
Scaptocoris castanea	Ra	Praga regionalmente importante
Cochonilhas-da-raiz	Ra	Secundária, importantes em áreas de semeadura direta

[1] Br = brotos; Co = cotilédones; Fj = folhas jovens; Fo = folhas; Ha = hastes; No = nódulos; Pe = pecíolos; Pl = plântulas; Pp = plantas pequenas; Ra = raízes; Se = sementes; Va = vagens.
(A) = adulto, (L) = larva.

Fonte: CORRÊA-FERREIRA (2012)(Modificada).

Nas últimas décadas, com o objetivo de manter o controle de insetos-praga em agroecossistemas, foi criado o Manejo Integrado de Pragas MIP (GALLO et al., 2002). O MIP visa manter a praga abaixo do Nível de Dano Econômico (NDE) e corresponde a um conjunto de tecnologias sustentáveis no controle de pragas, com o uso integrado de métodos de controle como, o químico, físico (exemplo, uso de armadilha luminosa), resistência de plantas (exemplo.

uso de plantas transgênicas) e biológico (uso de inimigos naturais de insetos-praga).

No Brasil, o MIP foi implantado em 1970, com o objetivo de orientar as decisões a respeito do controle dos insetos-praga, utilizando como base informações como densidade populacional dos insetos-praga e a incidência de inimigos naturais CORRÊA-FERREIRA (2012). Esse programa de manejo é de suma importância na identificação e controle dos insetos-praga da soja e seu uso reduz, consideravelmente, a utilização de inseticidas químicos (CAMPO et al., 2000). De acordo com AVILA; SANTOS (2018), antes da implementação do MIP eram realizadas de seis a sete aplicações de inseticidas químicos durante o ciclo da cultura da soja.

Os métodos de controle utilizados no MIP necessitam ser aplicados corretamente, na busca de evitar que decisões no manejo de insetos-praga sejam adotadas erroneamente, como uso de agrotóxicos de forma desnecessária. Em programas de MIP, as amostragens populacionais de pragas-chave (mais importantes, economicamente) e de inimigos naturais estão dentre as principais etapas para implementação de programas de MIP. Na cultura da soja, destacam-se métodos para amostragem de insetos-praga, como o pano-de-batida (CORRÊA-FERREIRA, 2012).

O Pano de Batida foi desenvolvido por Boyer e Dumas em 1963, nos Estados Unidos, para amostragem (avaliação populacional) de insetos-praga e inimigos naturais. Em 1980, esse método de amostragem foi considerado, como eficiente na captura e avaliação de lagartas e percevejos, além dos inimigos naturais em agroecossistemas. Para realizar esse método de monitoramento é necessário a utilização de um pano ou de um plástico branco (1 metro de comprimento x 1,5m de largura) e, nas extremidades, são inseridos cabos de madeira. Com o pano ainda enrolado ele é introduzido entre duas fileiras de soja e esticado sobre o solo, logo depois as duas fileiras de soja são batidas em direção ao pano, de forma que se inclinem, em seguida os insetos que se encontram no pano de batida são quantificados e registrados CORRÊA-FERREIRA (2012). Na Figura 3.1 é possível observar uma representação desse processo de utilização do pano de batida.

Figura 3.1: Representação da utilização do pano de batida.

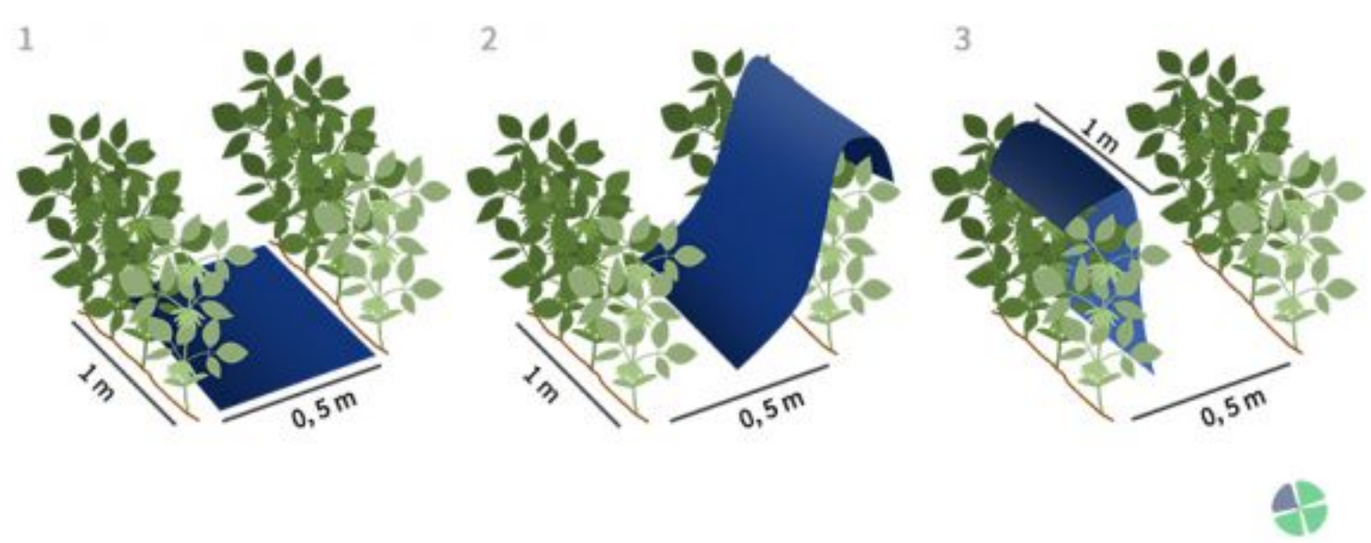

Fonte: Stürmer et al. (2012) adaptada, disponível em AGRO BAYER BRASIL (2022).

3.1.1 *Nezara viridula*

Os percevejos-verde *Nezara viridula* (Hemiptera: Pentatomidae), encontram-se principalmente na região sul do país. Esses percevejos, na fase adulta, possuem coloração verde e um tamanho de 12 a 15mm, vivem cerca de 70 dias, seus ovos possuem coloração amarela e são depositados na parte inferior das folhas,com capacidade de postura de 50 a 100 ovos/fêmea . Possuem cinco fases ninfais, na primeira fase medem entre 1,3mm a 3,1mm, possuem coloração preta e manchas brancas sobre o dorso. Nessa fase causam os danos na plantação não são expressivos. Na terceira fase ninfal começam a se alimentar dos grãos de soja de forma intensa e permanecem dessa forma assim até a quinta fase (medem 9mm) e a fase ninfal pode durar de 20 a 25 dias (Figura 3.2) (CAMPO et al., 2000).

Figura 3.2: Ciclo de desenvolvimento do percevejo-verde, *Nezara viridula*.

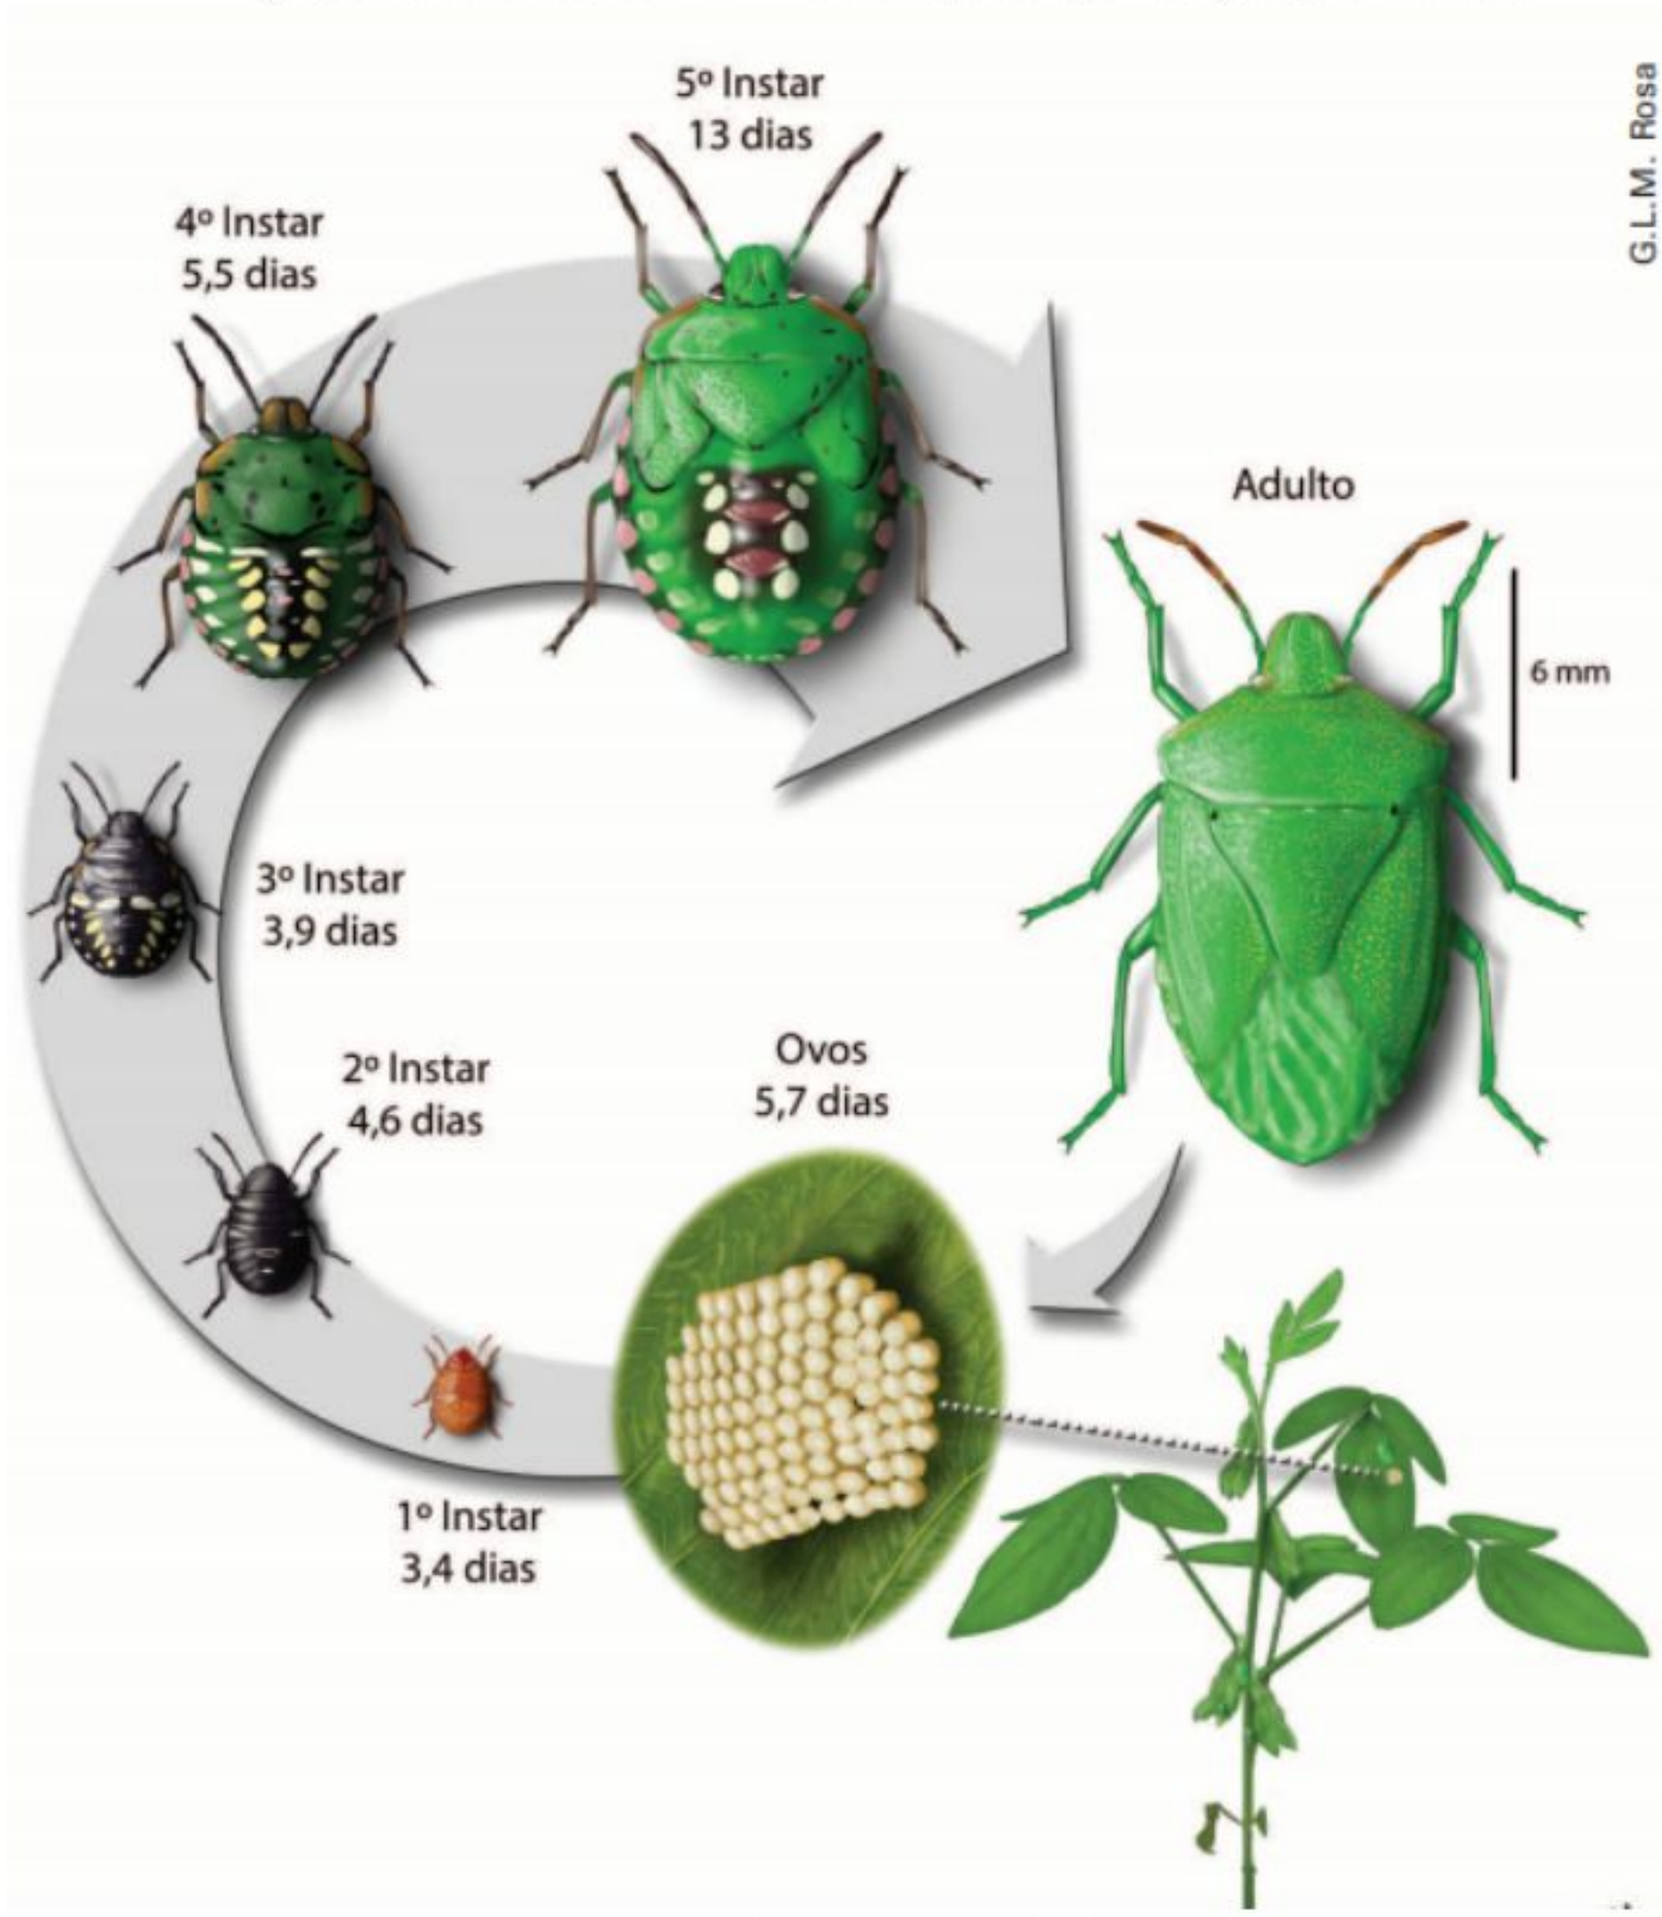

Fonte: CAMPO et al. (2012)

3.1.2 *Euschistus heros*

Os percevejos marrons *Euschistus heros* (Hemiptera: Pentatomidae), encontram-se principalmente na região Centro-Oeste e no norte do Paraná. São bem adaptados a climas quentes, em sua fase adulta possui uma coloração marrom-escuro, e possui ainda prolongamentos laterais em forma de espinho, vivem cerca de 116 dias, seus ovos são depositados em agrupamentos com 5 a 6 ovos (coloração amarela), e com manchas rósea próximo a eclosão, a oviposição pode ocorrer folhas ou mesmo nas vagens da soja. As ninfas, em sua fase inicial, medem 1mm e causam danos às sementes da soja e da terceira a quinta fase ninfal têm tamanho de 5 e 10 mm (Figura 3.3) (CAMPO et al., 2000).

Figura 3.3: Ciclo de vida do *Euschistus heros*: (a) adulto, (b) ovos, (c) ninfas recém-eclodidas, (d) ninfas de 5º ínstar.

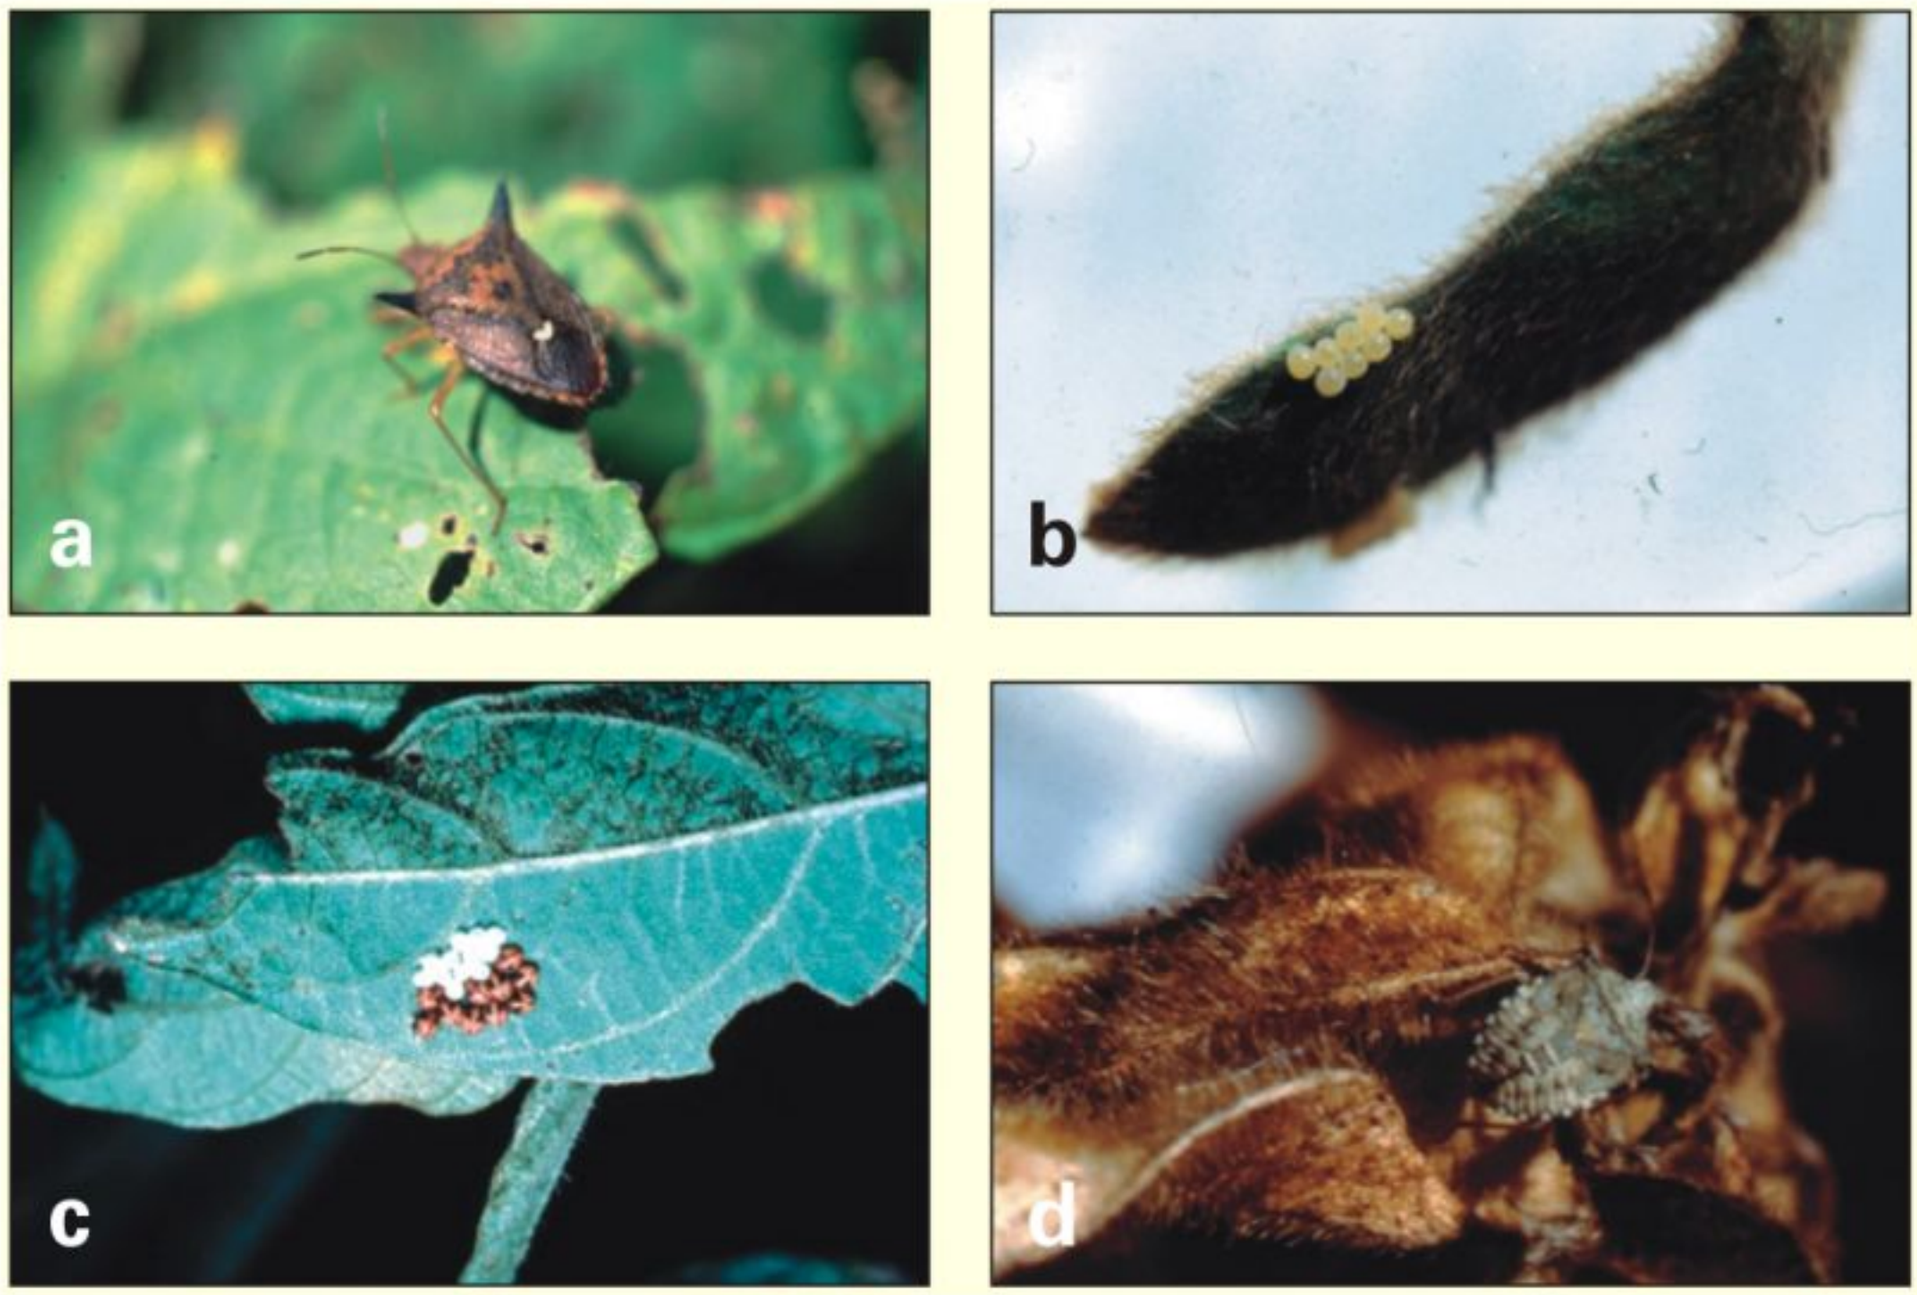

Fonte:CAMPO et al. (2000)

3.1.3 *Piezodorus guildinii*

O percevejo verde pequeno *Piezodorus guildinii* (Hemiptera: Pentatomidae). Sua ocorrência é desde o Sul do Brasil até o Norte e Nordeste. Na fase adulta medem em média 10mm e possuem uma coloração verde amarelada, com listras marrons avermelhadas e seus ovos são pretos. Durante a oviposição são colocados de 10 a 20 ovos em fileiras, que por sua vez são depositados nas vagens, folhas, caules e ramos a soja. As ninfas, em sua fase inicial permanecem no lugar onde os ovos foram colocados, medem 1mm de comprimento, nas fases 3 e 5 chegam aos 8mm (Figura 3.4) (CAMPO et al., 2000).

Figura 3.4: Ciclo de vida do *Piezodorus guildinii*: (a) adulto, (b) ovos, (c) ninfas recém-eclodidas, (d) ninfas de 5º ínstar.

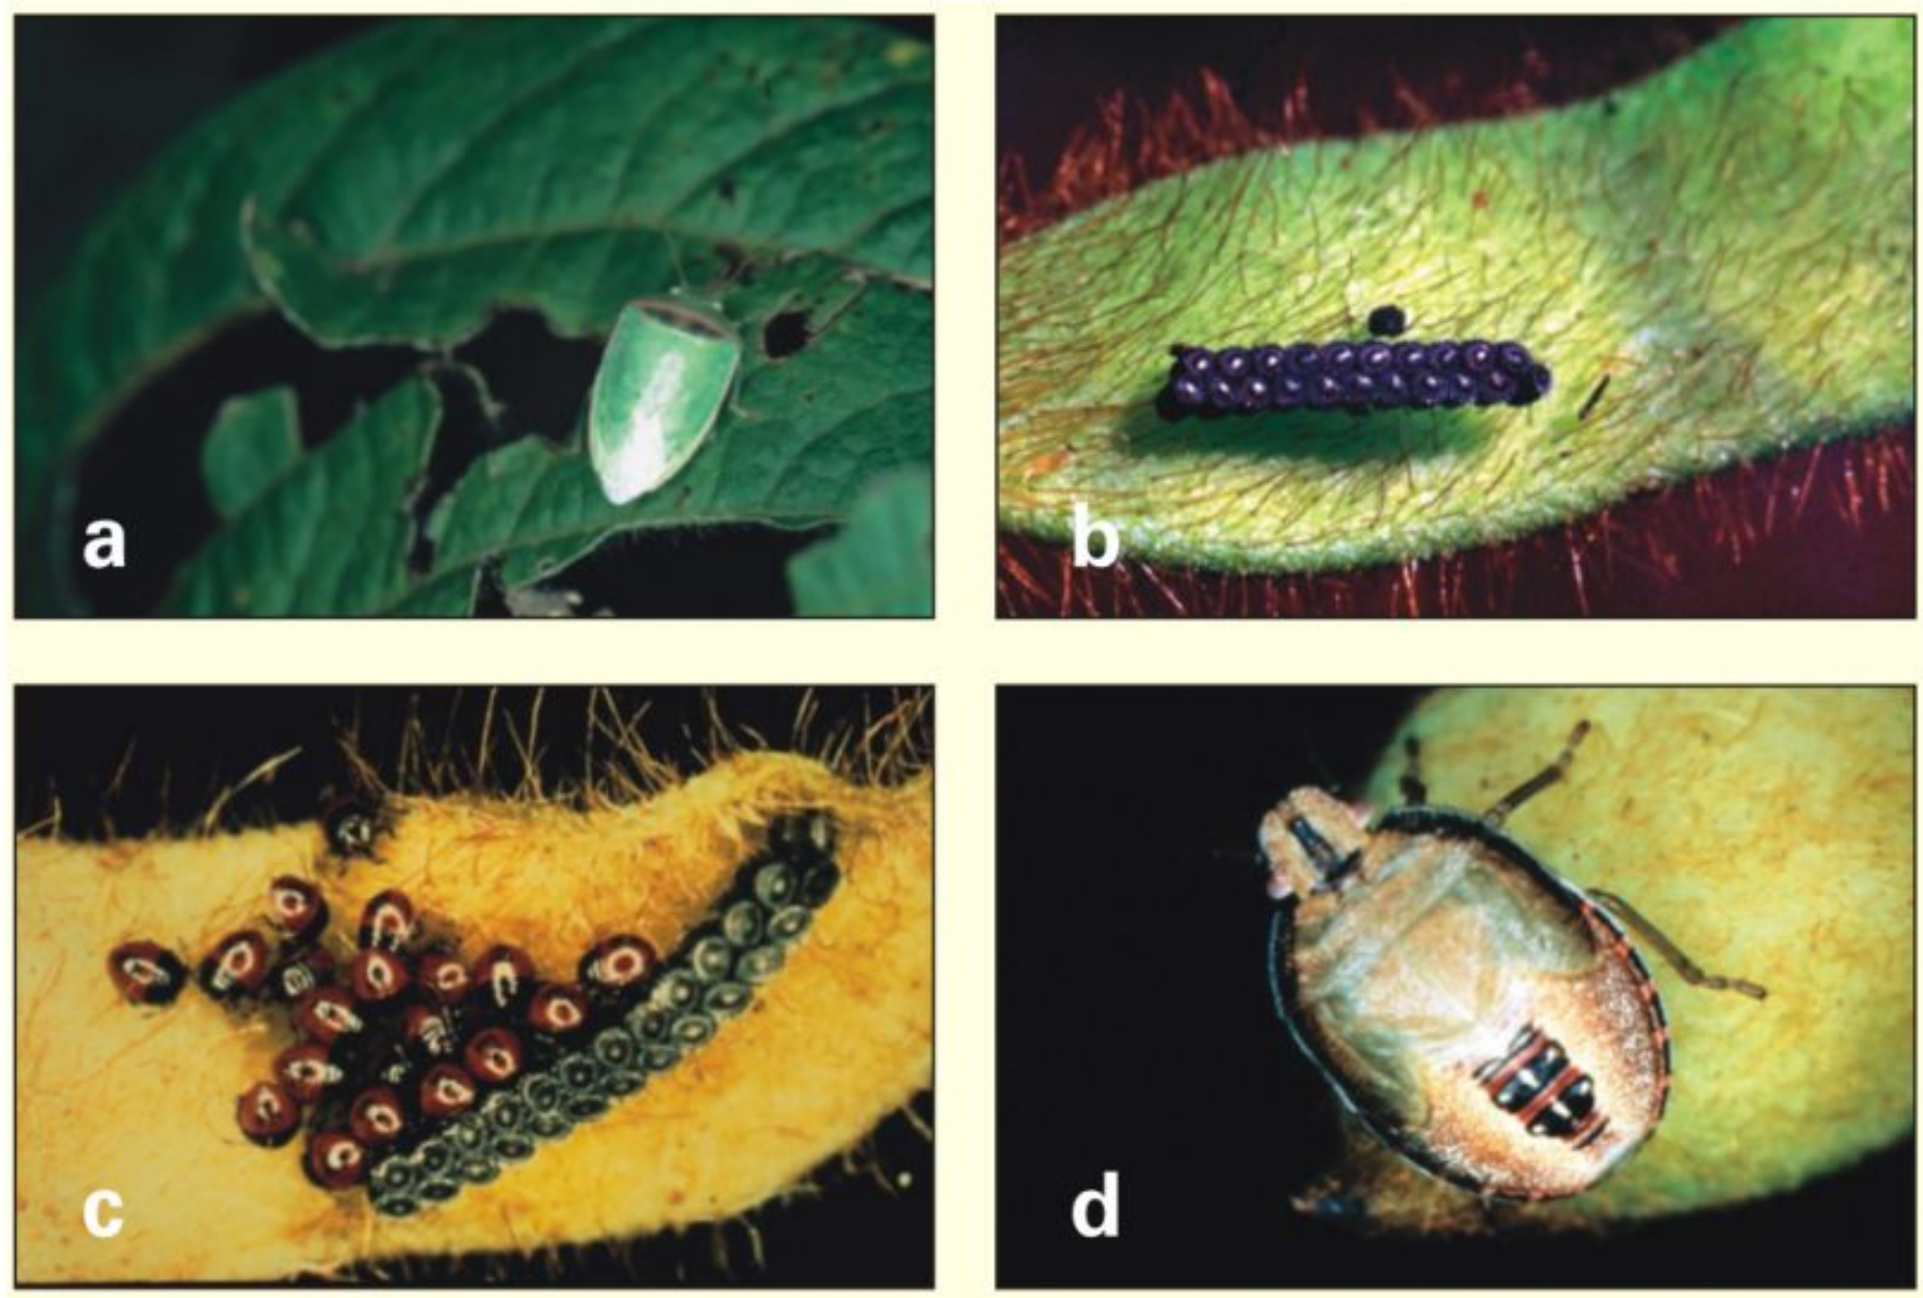

Fonte: CAMPO et al. (2000)

3.2 Inimigos Naturais

Os inimigos naturais são responsáveis por realizar o controle natural de insetos-praga. Dentre os inimigos naturais dos insetos-praga da soja foram selecionados alguns considerados de maior relevância para este trabalho, são eles:

3.2.1 "Tesourinhas" (Dermaptera: Forficulidae)

As tesourinhas (Dermaptera: Forficulidae) apresentam corpo alongado e estreito e medem de 4mm a 80 mm de comprimento. Possuem coloração preta ou marrom e apresentam asas anteriores curtas, além de um par de cercos em forma de pinça. Alimentam-se de ovos, lagartas, pupas, pulgões e mosca-branca. São insetos de hábito noturno e importantes predadores de insetos-praga, principalmente dos que se mantêm em partes protegidas das plantas (SUJII et al., 2020) (Figura 3.5).

3.2.2 "Crisopídeos" (Neuroptera: Chrysopidae)

Os crisopídeos (Neuroptera: Chrysopidae) atuam como predadores em sua fase larval, são ágeis e possuem pernas alongadas. Os adultos podem medir de 10 mm a 15mm, possuindo uma cor esverdeada, caso haja falta de alimento podem alimentar-se de sua ovipostura. Alimentam-se

Figura 3.5: Tesourinha (Dermaptera: Forficulidae)

Fonte: EMBRAPA (2014)

de pulgões, cochonilhas, tripes, mosca-branca, psilídeos, larvas de lepidópteros, ácaros entre outros. São conhecidas como bicho-lixeiro, pois carregam os restos de suas presas (SUJII et al., 2020) (Figura 3.6).

Fonte: EMBRAPA (2014)

Figura 3.6: Crisopídeos (Neuroptera: Chrysopidae)

3.2.3 "Joaninhas" (Coleoptera: Coccinelidae)

As joaninhas (Coleoptera: Coccinelidae), em sua forma adulta, possuem o corpo arredondado, coloridos e podem chegar a 10 mm. São encontradas em hortas, pomares, vegetação nativa ou grandes culturas. As larvas são ágeis e seu corpo é recoberto de secreção de cor branca. Podem alimentar-se de pulgões, cochonilhas, algumas espécies de ácaros, alguns hemípteros e ainda de ovos de insetos (SUJII et al., 2020) (Figura 3.7).

Fonte: EMBRAPA (2014)

Figura 3.7: Joaninha (Coleoptera: Coccinelidae)

4

Revisão de Literatura

Este capítulo é resposável por apresenta uma revisão de literatura, utilizando artigos científicos, dos últimos seis anos, com o objetivo de explorar pesquisas que utilizam técnicas de Visão Computacional para a identificação de insetos-praga. Foram utilizadas as bases *Elsevier*, *Google Scholar*, *IEEE Xplore* e *Scielo*, as palavras chave para a pesquisa foram: identificação, insetos praga, visão computacional, rede neural, soja.

A Visão Computacional tem sido amplamente implementada em áreas da agricultura para obter informações de imagens, a fim de realizar detecção de eventos. Ao longo dos últimos anos, a detecção de pragas tem sido um alvo importante de automatização. Esse processo é realizado de maneira manual no manejo de pragas e tem como objetivo detectar e realizar a quantificação e qualificação de pragas. Pesquisadores têm se dedicado a utilizar técnicas de inteligência artificial e *machine learning* para encontrar soluções, que são possíveis devido aos dos avanços dessas técnicas.

KASINATHAN et al. (2020) desenvolveram algoritmos para detectar e classificar os insetos-praga em cultivos de milho, soja e trigo na fase inicial da cultura. Foram utilizados recursos, como redes neurais artificiais, redes neurais convolucionais (CNN), *support vetor machine* (SVM), *k-nearest neighors* (KNN) e *naive bayes* (NB). Além disso, utilizaram dois conjuntos de dados, um deles com o total de duzentos e vinte e cinco imagens, e o outro com setecentos e oitenta e cinco imagens. Inicialmente, foi realizado o pré-processamento de imagens, a fim de reduzir os ruídos e tornar as imagens mais nítidas. Logo após, foi aplicado um redimensionamento das imagens. Dessa forma, os conjuntos de dados expandiram, sendo o primeiro conjunto de dados seis mil duzentos e oitenta dados e o segundo conjunto de dados mil duzentos e noventa e seis. Foram realizadas as extrações de recursos e então aplicou-se cada uma das propostas. O classificador de rede neurais utilizou duas camadas de entrada e uma de saída, o classificador SVM utilizou uma função de núcleo base radial, em KNN o número de vizinhos foram dez e o NB foi adaptado para gerar uma classificação em tempo mínimo. Enquanto que, o modelo de CNN foi observado uma taxa de aprendizagem de 0,001. Ao final, foi comparada a taxa de acerto dos algoritmos, sendo o mais eficiente o CNN, alcançando uma taxa de acerto de 93,9% para 5 classes de pragas e 91,5% para 9 classes.

SILVA et al. (2019) realizaram revisão sistemática de literatura, dos trabalhos publicados

entre 2008 e 2018. Estes trabalhos abrangem métodos de processamento digital de imagens de plantas, a fim de detectar e classificar pragas, sendo seu foco principal a mosca-branca *Bemisia* sp. (Hemiptera: Aleyrodidae). Nos últimos dez anos foram publicados, em média, duas pesquisas (artigos), por ano, a respeito do assunto. Os trabalhos que utilizavam o método de armadilhas adesivas, observou-se que o sistema de processamento de imagens teve dificuldade de detectar as mocas-brancas que se encontravam nas bordas das armadilhas, enquanto que, os trabalhos em que as imagens foram retiradas diretamente das folhas, a dificuldade foi detectar as ninfas em estágios iniciais. Para trabalhos posteriores é sugerido a utilização de imagens retiradas por dispositivos móveis.

TETILA et al. (2020) apresentaram uma comparação entre cinco arquiteturas de aprendizagem profunda e realizaram a comparação com outros métodos de *machine learning*, utilizando um conjunto de 5.000 imagens obtidas de um campo de cultivo de soja em condições reais, a fim de qualificar treze pragas. As imagens foram obtidas em diferentes horários do dia e diferentes condições climáticas. Foram utilizados três critérios para avaliar as arquiteturas, acurácia, tempo de treinamento e erro de aprendizagem. A arquitetura Resnet-50 obteve precisão de 9,82%, a Inception-V3 obteve precisão de 91,87% , arquiteturas VGG-19 obtiveram precisão de 91,33% e Xception obteve precisão de 90,52%. Aplicou-se ainda, um teste para identificar se as arquiteturas diferem estatisticamente. Porém, nenhuma diferença significativa foi encontrada. Ao final, foi constatado que o desempenho de arquiteturas de aprendizagem profunda, com ajustes finos e transferência de aprendizagem, alcançaram a maior precisão, como é o caso da Resnet-50.

LIU et al. (2019) propuseram uma Rede Neural Convolucional em aprendizagem profunda de ponta a ponta, denominada *PestNet*, esta utiliza-se de uma Região de Rede de Propostas (RPN) com o objetivo de detectar e classificar multiclasses de pragas. Para alcançar seu objetivo analisaram um banco de mais de oitenta mil imagens, construído ao longo de dez anos, nas quais foram rotuladas por especialistas quinhentos e oitenta mil pragas divididas em dezesseis classes. Na construção do conjunto de dados foi necessário a utilização de armadilhas de luz. Ao serem atraídas pela luz, as pragas atordoadas caiam sobre uma bandeja e então foram fotografadas. Para a localização do inseto na imagem, foi utilizado um método de mapa de pontuação sensível à posição, em combinação com o RPN. Devido aos métodos de ponta a ponta não foi necessário nenhum tipo de pré-processamento ou intervenção humana. Todo o processo foi dividido em três estágios, sendo eles, extração de características das pragas, pesquisa de região e previsão. Algumas questões foram intratáveis, como imagens embaçadas ou objetos minúsculos nas imagens, apesar disso, o *PestNet* obteve uma porcentagem de acerto de 75,46%. O sistema foi capaz de distinguir pragas de uma mesma classe ainda sob posições diferentes como lado, frente ou região posterior. Além disso, obteve-se êxito em diferenciar as classes que possuíam semelhanças.

SOUZA; ALVES; BORGES (2019) propuseram uma modificação no modelo de aprendizagem profunda *Inception-V3* para realizar o reconhecimento de seis insetos-praga em plantações de milho. O conjunto de dados foi coletado diretamente do campo em vários estágios da plantação, a fim de reconhecer as pragas mais frequentes. As imagens passaram por uma ampliação,

o que resultou em um aumento na quantidade de imagens adquiridas inicialmente, sendo o conjunto de quatro mil trezentos e vinte imagens. Para a modificação do modelo, o intuito foi realizar uma combinação de camadas de regularização com pesos diferentes para adquirir uma precisão melhor, criando uma estrutura dividida em quatro partes. Na primeira parte localizada as camadas de regularização, na segunda parte uma camada linear, seguida de uma função de ativação, na terceira parte um par de camadas de regularização seguindo a mesma ordem da anterior e na quarta parte uma camada linear, a fim de preparar a previsão de saída. Dessa forma, na camada de regularização é evitado que o modelo trabalhe com os mesmos pesos e na camada linear o número de pesos é reduzido. Esse descarte de pesos, auxilia o modelo na generalização das previsões para novos dados de entrada, reduzindo a possibilidade de *overfitting*, obtendo o modelo um melhor desempenho. Ao final dos experimentos o *Inception-V3* modificado obteve uma taxa de acerto de 97,0%, alcançando um melhor desempenho e melhor tempo de treinamento do que *Inception-V3* regular, o qual obteve uma taxa de acerto de 94,8%.

SRIWASTWA et al. (2018) buscaram identificar insetos-praga com segmentação de imagens baseada em cores. Para alcançar tal objetivo, o primeiro passo foi realizar o pré-processamento das imagens, a fim de melhorar a qualidade das gravuras. Logo após, foi realizada a segmentação das imagens, baseada nas cores, estas foram convertidas de RGB em L*a*B e então foi aplicado o algoritmo de agrupamento *K-Means*. As informações relacionadas às cores foram armazenadas em uma camada de cromaticidade. As imagens utilizadas foram retiradas de diferentes fontes na *web* e incluem insetos-praga em plantações de cana-de-açúcar, plantação de milho e de arroz. O grande desafio desta técnica foi identificar a praga em imagens com sombreados ou quando havia intensa quantidade de pragas. Apesar disso, essa técnica se mostrou mais eficiente que as segmentações baseadas em bordas.

SILVA et al. (2015) buscaram desenvolver um sistema de identificação de insetos-praga presentes no cultivo da soja, utilizando o reconhecimento de imagens. As imagens foram obtidas após a coleta de insetos-praga pelo método de pano-de-batida, método este, já utilizado no manejo de pragas no cultivo da soja. Para alcançar o objetivo, esses autores aplicaram técnicas de visão computacional. Foram utilizados dois algoritmos, denominados *SURF* e *SIFT*. Eles são responsáveis pela detecção de pontos de interesse nas imagens, para que, posteriormente, seja realizado um alinhamento entre os pontos de interesse das imagens buscadas e as imagens de entrada. Ao final, foi obtido uma taxa de acerto de 85% na detecção de percevejos. A tabela 4.1 sumariza a revisão de literatura realizada, apresentando em cada estudo o método computacional utilizado e a disponibilidade dos dados.

Tabela 4.1: Resumo da Revisão de Literatura

Artigo	Método	Dados
SILVA et al. (2015)	SURF e SIFT	Não dísponivel.
Sriwastwa et al. (2018)	K-Means	Disponíveis em:https://www.india.gov.in/farmers -portal-india-department- agriculture-and-cooperation.
SILVA et al. (2019)		Não Disponível.
LIU et al. (2019)	Rede Neural Convolucional	Disponíveis em: https://www.image-net.org/.
SOUZA; ALVES; BORGES (2019)	Rede Neural, *Inception-V3*	Dados coletado diretamente em campo. Não dísponivel.
KASINATHAN et al. (2020)	Rede Neural Convolucional-ALexNet,SVM,Naive Bayes,k-nearest Neighors	Disponíveis em:http://159.226.67.82/pubs.htm, http://www2.ahu .edu.cn/pchen/web/ insectRe-cognition.htm.
TETILA et al. (2020)	Inception-V3,VGG-19,Xception,Resnet-50	Disponíveis em: https:// bit.ly/2SKp9jC.

5

Projeto

Neste capítulo foi aprestado os materiais e métodos utilizados no desenvolvimento do projeto, os passos realizados desde da aquisição das imagens até a construções dos modelos utilizados em *Python*. Escolheu-se utilizar a arquitetura de rede neural convolucional *ALEXNET* uma vez que ela se adapta muito bem com imagens RGB além de ter sido utilizada em em trabalhos que se encontram na revisão de literatura. Na Figura 5.1 foi elaborado um diagrama com as etapas realizadas.

Figura 5.1: Diagrama das Etapas Realizadas no Projeto.

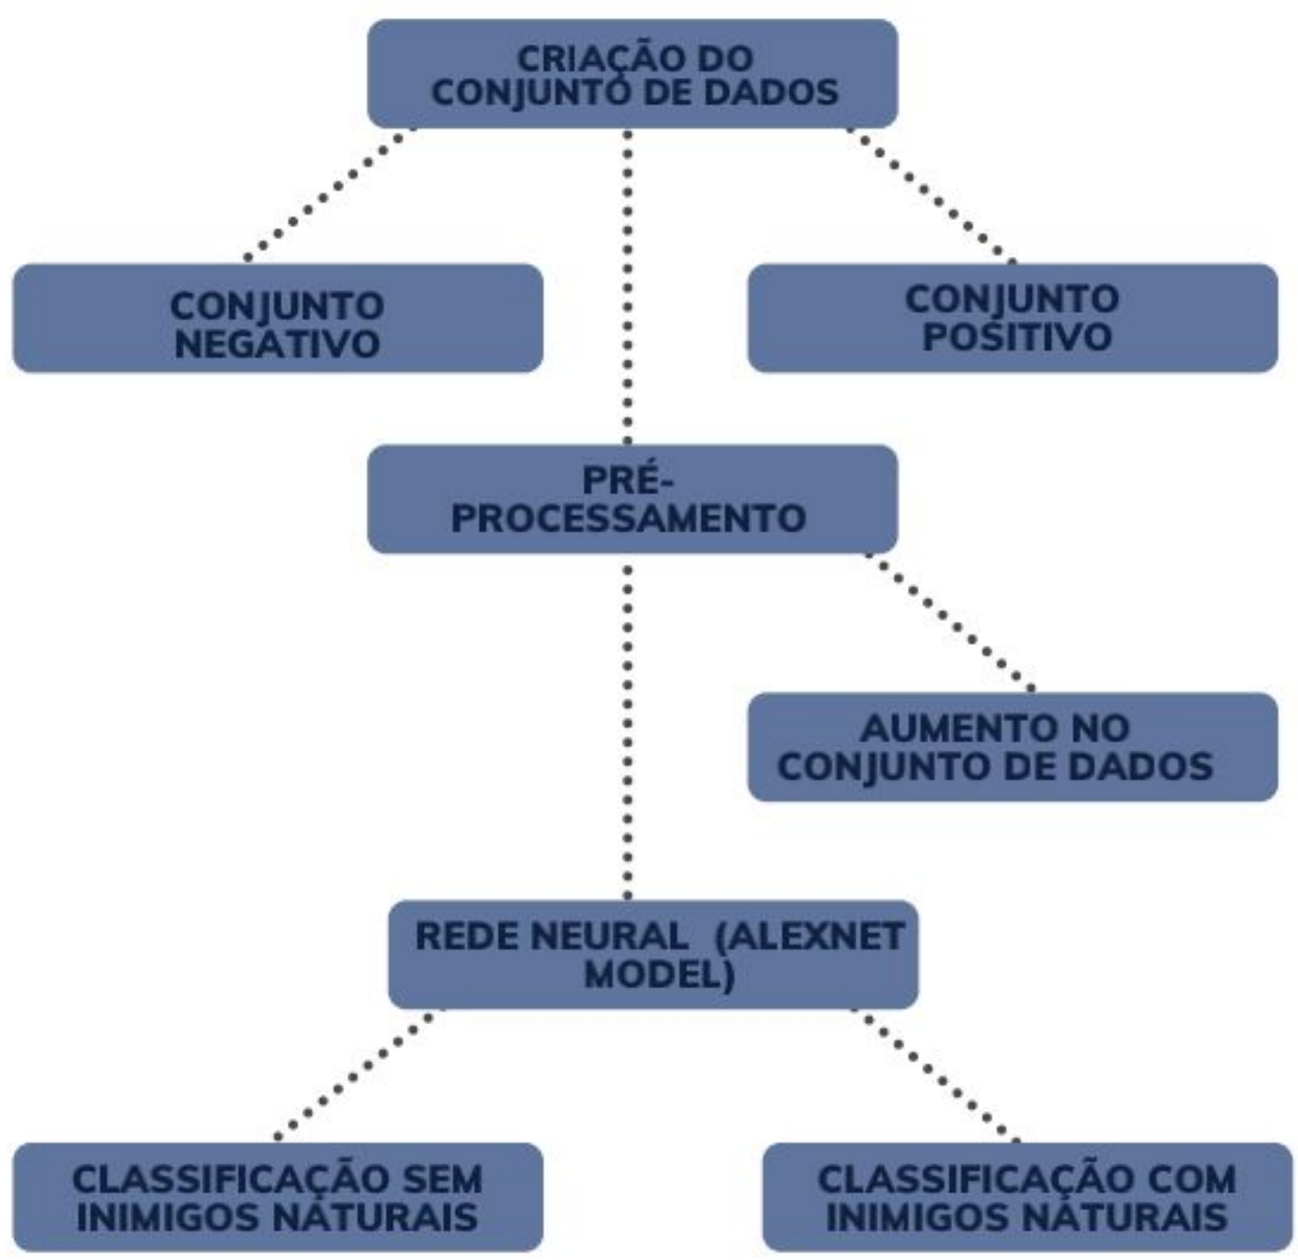

5.1 Considerações sobre o Método de Visão Computacional proposto no projeto.

Inicialmente o projetos consistiu em realizar duas classificações, uma utilizando uma CNN simples e outra utilizando a arquitetura *ALEXNET*. Foram realizados diferentes experimentos, nos quais as imagens passaram pelo processo de aumento no conjunto utilizando uma função da biblioteca do *Keras* que realiza transformações de rotações, inversões, cortes e zoom de forma aleatória. Após, foram aplicados filtros *Blur* e *Canny*, foi realizado ainda o redimensionamento das imagens. Posteriormente, as imagens foram submetidas a rede neural CNN simples e a *ALEXNET*, mas não foram alcançados resultados de classificação satisfatórios, uma vez que o maior resultado encontrado foi de 62%. Portanto optou-se por alterar o método de Visão Computacional conforme descrição a seguir.

5.2 Criação dos Conjuntos de Dados

Nesta etapa foi realizado a criação dos conjuntos de dados, esses foram divididos em conjuntos negativos e conjuntos positivos. Foram criados dois conjuntos negativos, o primeiro contém imagens de folha de soja não contendo insetos, no segundo contém as imagens de inimigos naturais. No conjunto positivo, foram usadas imagens que contenham os insetos-praga que pretende-se identificar. As imagens utilizadas foram extraídas de bancos de dados de imagens como disponibilizado em TETILA et al. (2020). Dentre os trabalhos de identificação de insetos-praga em plantações de soja o presente trabalho destaca a utilização dos inimigos naturais dentro do conjunto de imagens negativos que será explicado adiante.

Para a criação do conjunto de imagens a primeira etapa consistiu em definir os conjuntos negativos e positivos, sendo assim foi realizada a etapa de aquisição das imagens. No total o conjunto de imagens possui 3.490 imagens (formado por 711 *E. heros*, 54 , *P. guildinii* e 229 *N. viridula*, 2.208 imagens que não possuem insetos, apenas folhas de soja, 127 Chrysopidae , 133 Coccinelidae e 27 Forficulidae). A fim de balancear o conjunto de imagens foram utilizadas a seguinte quantidade de imagens:

- Conjunto Positivo: Tabela 5.1

Tabela 5.1: Composição do Conjunto Positivo experimento com inimigos naturais

E. heros	***P. guildinii***	***N. viridula***	**Folhas (soja)**
300	46	100	0

- Conjunto Negativo: Tabela 5.2

Para a classificação sem a adição dos inimigos naturais foram realizadas as mesmas etapas, a principal diferença encontra-se na formação do conjunto negativo, sendo assim os conjuntos foram definido da seguinte forma:

Tabela 5.2: Composição do Conjunto Negativo experimento com inimigos naturais

Chrysopidae	Coccinelidae	Forficulidae	Folhas (soja)
50	50	27	50

- Conjunto Positivo: Tabela 5.1
- Conjunto Negativo: Tabela 5.3

Tabela 5.3: Composição do Conjunto Negativo experimento sem inimigos naturais

Chrysopidae	Coccinelidae	Forficulidae	Folhas (soja)
0	0	0	50

Em sua maioria as imagens foram retiradas do repositório disponibilizado pelos autores TETILA et al. (2020), as demais imagens foram retiradas de *sites* de imagens. De forma geral, o conjunto de dados consistiu em imagens retiradas diretamente de plantações possuindo um fundo nos quais as folhagens da soja estavam presentes, existem também, dentro dos conjuntos, imagens de fundo branco.

5.3 Pré-Processamento

Nesta etapa foi utilizada a técnica de aumento do conjunto de imagens assim como executado por KASINATHAN et al. (2020) e SOUZA; ALVES; BORGES (2019), realizando rotações e inversões. Foi implementado um algoritmo em *python* que realizou o aumento. Uma vez que o modelo de rede neural escolhido trabalha muito bem com as imagens coloridas e não exige a utilização de filtros, as imagens foram submetidas a rede sem a necessidade desses processos. Esse processo consiste em criar imagens a partir de outras utilizando diferentes formas de processamento ou de combinações de processamento como giros, deslocamento e rotações, com o objetivo de aumentar a diversidade de imagens para o treinamento. De acordo com KASINATHAN et al. (2020) esse processo é importante ainda para melhorar a precisão e eliminar os problemas de *overfitting* (ocorre quando o modelo estatístico se ajusta ao conjunto de dados de forma eficiente mas não é capaz de prever novos resultados). Primeiramente as imagens foram redimensionadas para 277x277. Após o redimensionamento, as imagens sofreram uma redução na representação das suas cores, a fim de resolver este problema e as imagens voltarem a suas cores originais, elas foram convertidas para o sistema RGB. Depois as imagens foram submetidas a rotações nos ângulos de 90º, 180º, 270º e inversões horizontais para cada ângulo rotacionado assim como feito por KASINATHAN et al. (2020), sendo assim para cada imagem

são geradas 6 imagens, ao final foram obtidas 6.111 imagens. Na Figura 5.2 é possível visualizar um exemplo.

Figura 5.2: *P. guildinii* após o aumento de imagens. (Original) Imagem original, (90º) Imagem rotacionada a 90º, (180º) Imagem rotacionada a 180º, (270º) Imagem rotacionada 270º, (90º Invertido) Imagem rotacionada a 90º e invertida horizontalmente, (180º Invertido) Imagem rotacionada a 180º e invertida horizontalmente 270º Invertido) Imagem rotacionada a 270º e invertida horizontalmente.

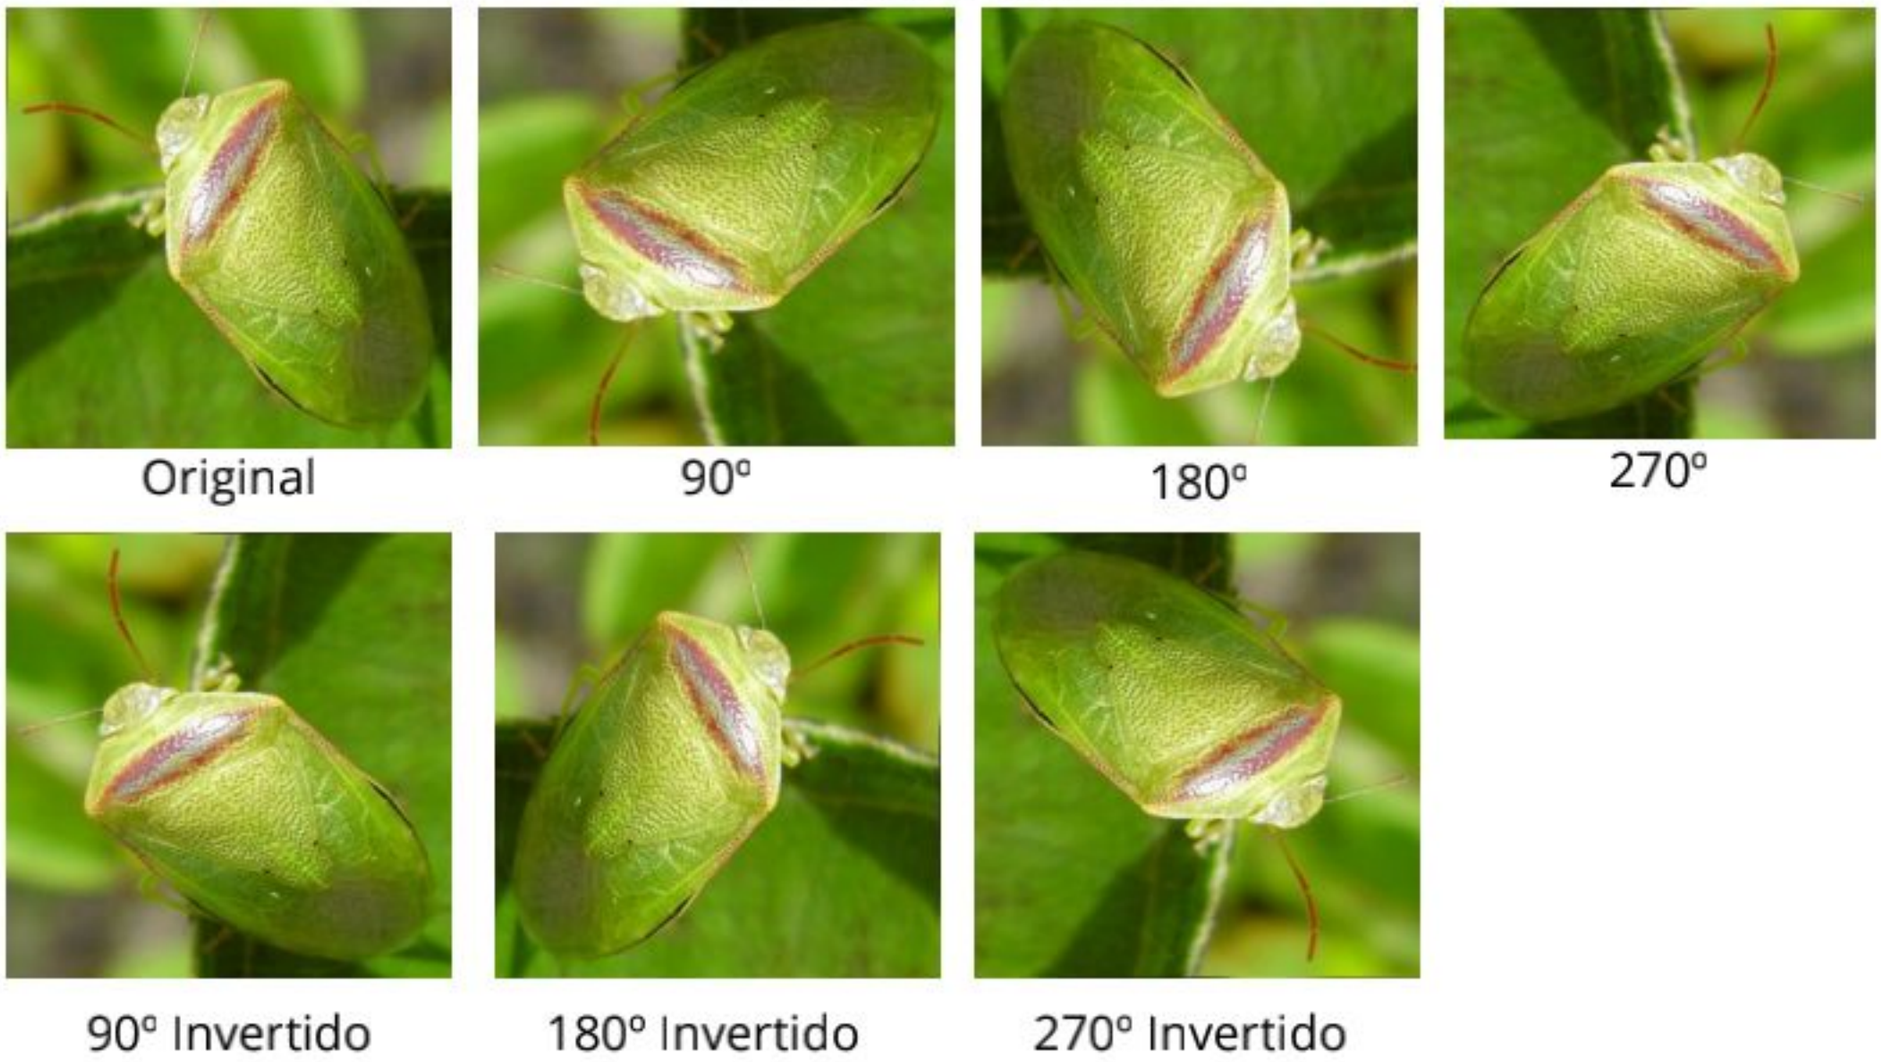

5.4 Classificação com inimigos naturais

Para a classificação com os inimigos naturais o primeiro passo foi rotular o conjunto de imagens em pragas e não praga, sendo assim foram rotulados como praga *E. heros*, *P. guildinii*, *N. viridula*, todos os demais foram rotuladas como não pragas. Logo depois os conjuntos de imagens foram divididos em treinamento e teste. Essa divisão foi realizada de forma aleatória, sendo 70% dos dados foram colocados no conjunto de treino e 30% no conjunto de teste. Posteriormente os dados de treinamento foram embaralhados e, então foi construída a rede neural *ALEXNET*, uma vez que a mesma foi utilizadas em trabalhos como TETILA et al. (2020), LIU et al. (2019) e SOUZA; ALVES; BORGES (2019). A escolha dessa arquitetura pode ser justificada ainda pela mesma se mostrar eficiente para imagens em sistema de cores RGB, sem a necessidade da aplicação de filtros.

5.5 Classificação sem inimigos naturais

Para a classificação sem inimigos naturais foram utilizados os mesmo passos da classificação anterior. A diferença se encontra na parte de rotulação, para essa classificação foram

rotuladas como praga as imagens de *E. heros*, *P. guildinii*, *N. viridula*, como não praga foram rotuladas todas as imagens de folhas de soja sem insetos. A implementação e os dados utilizados estão disponíveis no *Github* no link: https://github.com/Raquel29/IDENTIFICA-O-DE-INSETOS-PRAGA-DA-CULTURA-DE-SOJA-COM-VIS-O-COMPUTACIONAL

6

Resultados e Discussão

Neste capítulo foram descritos os resultados e discussão dos experimentos realizados com cada um dos modelos propostos, um contendo os inimigos naturais no conjunto negativo e no outro contendo apenas imagens sem a presença de insetos no conjunto negativo..

6.1 Experimentos

Para o primeiro experimento as imagens foram submetidas ao modelo *ALEXNET*, com classificação binária (pragas e não pragas). O treinamento foi realizado três vezes o que gerou um resultado acurácia média de 90%. Ao final do experimento foi obtida uma acurácia de 92%. Foram calculadas, ainda, as seguintes métricas de avaliação *recall*, com um resultado de 92% indica a sensibilidade, *precision* com 92% o que indica a razão entre os verdadeiros positivos e o total dos classificados como positivos, *F-score* com um resultado de 92% representa a média harmônica entre *recall* e a *precision*.

Para a classificação sem a presenças dos inimigos naturais, o segundo experimento consistiu em reproduzir o que foi anteriormente realizado, então novamente o conjunto foi dividido em duas classes, praga e não praga. As imagens foram submetidas aos mesmos processos citados anteriormente de pré-processamento e segmentação. Após as imagens foram submetidas ao modelo *ALEXNET* com 50 épocas para treino. O treinamento foi realizado três vezes o que gerou um resultado acurácia media de 90%. Foi obtido uma acurácia final de 91%, e demais métricas *precision* 91%, *recall* 91% , *F-score* de 91%.

6.2 Discussão dos resultados

Na tabela 6.1 é possível observar um resumo dos experimentos realizados, o melhor resultado encontrado foi de 92%, que foi superior aos resultados encontrados por SILVA et al. (2015) de 85%. Deve-ser considerar que o mesmo utilizou imagens de percevejos, porém em seu conjunto de imagens haviam imagens dos insetos em suas fases ninfais, o que dificulta a classificação, não havendo ainda a presenças dos inimigos naturais. Outro resultado muito próximo foi encontrado pelos autores KASINATHAN et al. (2020) com diferentes classes de insetos encontraram 91,5% em seu resultado. TETILA et al. (2020) encontraram um resultado

de 93,82%. Todos esses autores realizaram classificação multiclasse, com arquiteturas de rede neurais convolucionais diferentes da proposta neste trabalho. Existem diferenças ainda quanto a composição dos conjuntos de imagens que foram propostos nesta pesquisa. No primeiro experimento encontra-se a presença dos inimigos naturais, enquanto no segundo não, nos resultados aqui encontrados verifica-se que não houve uma grande diferença na acurácia dos experimentos 1 e 2 . Sendo assim os resultados sugerem que a presença dos inimigos naturais foi capaz de aumentar em 1% no resultado final do modelo, ou seja, não foram capazes de exercer uma diferenças significativa. Pode-se ressaltar que durante a etapa de classificação primeiramente procurou-se utilizar todas as imagens que foram inicialmente coletadas. As imagens chegaram a ser submetidas ao processo de aumento de imagens gerando um conjunto total de cerca de 25.000 imagens. Entretanto foram enfrentados problemas de exceção de memoria RAM devido as grande quantidade de imagens e resolução, a solução encontrada foi reduzir o conjunto de imagens antes mesmo de que ele fosse submetido ao processo de aumento do conjunto de imagens.

Tabela 6.1: Resumo dos Resultados dos experimentos 1 e 2

Experimento	Acurácia	Recall	Precision	F-score
Experimento 1	92%	92%	92%	92%
Experimento 2	91%	91%	91%	91%

7

Conclusões

O presente trabalho realizou a identificação de insetos-praga aplicando uma rede neural com arquitetura *ALEXNET* para classificações com o uso de dois diferentes conjuntos negativos, as imagens foram redimensionadas, embaralhadas e pré-processadas, o conjunto de dados passou por uma etapa de aumento para melhora da precisão do modelo. Nos resultados finais a melhor classificação foi utilizando o conjunto contendo os inimigos naturais que obteve acurácia de 92% e F-score de 92%, enquanto sem a utilização obteve acurácia de 91% e F-score de 91%, obtendo exito em sua classificação. Buscou-se, através dos experimentos realizados, avaliar o impacto da adição de inimigos naturais ao conjunto negativo de um dos experimentos, os resultado sugerem que a adição dos inimigos naturais foi capaz de gerar uma classificação 1% mais alta. O que demonstra que a adição dos inimigos naturais não exerceu um impacto relevante no resultado final do modelo, se mostrando tão eficiente quanto a classificação sem a adição dos mesmos.

Com os resultados obtidos é possível observar que as duas abordagens obtiveram um ótimo desempenho, portanto a arquitetura de rede neural *ALEXNET* utilizada mostrou-se eficaz para a identificação de insetos pragas. Para trabalho futuros sugere-se a classificação com todo o banco de dados originalmente obtido, a adição de imagens de percevejos em suas fases ninfais também poderia ser testada, pode-se ainda a realizar uma classificação multiclasses, testando diferentes arquiteturas de redes neurais convolucionais.

AGRO BAYER BRASIL, A. **Métodos para estimativas da população de percevejos.** Disponível em `https://www.agro.bayer.com.br/mundo-agro/agropedia/metodos-para-estimativas-da-populacao-de-percevejos` Acesso em 29 de outubro de 2022.

ALAKE, R. Implementing AlexNet CNN Architecture Using TensorFlow 2.0+ and Keras. **Towards Data Science**, [S.l.], 2020.

ALBUQUERQUE FILHO, O. M.; ALBUQUERQUE NETO, H. V. Processamento Digital de Imagens. **Revista Brasileira de Geofísica**, [S.l.], 2003.

AVILA, C. J.; SANTOS, V. Manejo Integrado de Pragas (MIP) na Cultura da Soja. **Embrapa Agropecuária Oeste**, [S.l.], v.143, 2018.

BASH, S. H. S. et al. Disciplina de Processamento de Imagens. **Neurocomputing**, [S.l.], p.112–119, 2020.

BONATO, E. R. B.; VARIANI, A. L. A soja no Brasil: história e estatística. **EMBRAPA-Empresa Brasileira de Pesquisa Agropecuária**, [S.l.], n.21, p.1–61, 1987.

CAMPO, C. B. H. et al. Pragas da soja no Brasil e seu manejo integrado. **Circular Tecnica - EMBRAPA Soja (Brazil).**, [S.l.], n.30, p.1–70, 2000.

CAMPO, C. B. H. et al. Soja: manejo integrado de insetos e outros artrópodes-praga. **Circular Tecnica - EMBRAPA Soja (Brazil).**, [S.l.], p.335–420., 2012.

CONAB, a. Acompanhamento da Safra Brasileira de Grãos. **Observatório Agrícola**, [S.l.], v.2, p.1–60, 2021.

CORRÊA-FERREIRA, B. S. Amostragem de pragas da soja. **Soja: manejo integrado de insetos e outros artrópodes-praga**, [S.l.], p.631–672, 2012.

EMBRAPA. Controle Biológico. **AgriShow**, [S.l.], 2014.

FARIA, F. A. **Disciplina de Processamento de Imagens**. , [S.l.], p.1–53, 2015.

FILHO, O. M.; NETO, H. V. **Processamento Digital de Imagens**. [S.l.: s.n.], 1999.

FREITAS, M. de Campos Martins de. A CULTURA DA SOJA NO BRASIL: o crescimento da produção brasileira e o surgimento de uma nova fronteira agrícola. **Enciclopédia Biosfera**, [S.l.], v.12, n.22, p.119–128, 2011.

GALLO, D. et al. Entomologia Agrícola. **Fundação de Estudos Agrários**, [S.l.], v.10, p.1–469, 2002.

GONDIN, P. H. R. **Industrialização da soja no Brasil**. , [S.l.], p.1–33, 2019.

JAIN, R. et al. **Machine Vision**. [S.l.]: McGraw-Hill, 1995. 1-549p.

KASINATHAN, T. et al. Insect classification and detection in field crops using modern machine learning techniques. **Information Processing in Agriculture**, [S.l.], v.8, 2020.

KRISHNA, R. **COMPUTER VISION: foundat i ons and applications**. , [S.l.], p.17–24, 2017.

KRIZHEVSKY, A. et al. ImageNet Classification with Deep Convolutional Neural Networks. **Handbook of Approximation Algorithms and Metaheuristics**, [S.l.], p.1–9, 2012.

LIU, L. et al. PestNet: an end-to-end deep learning approach for large-scale multi-class pest detection and classification. **IEEE Access**, [S.l.], v.7, p.12, 2019.

NANNI, L. et al. Insect pest image detection and recognition based on bio-inspired methods. **Ecological Informatics**, [S.l.], v.57, p.1–9, 2020.

OLIVEIRA, P. R. Redes Neurais Artificiais para Extração de Características. **Catálogo USP**, [S.l.], p.1–105, 1997.

QUEIROZ, J. E. R. de; GOMES, H. M. Introdução ao Processamento Digital de Imagens. **RITA**, [S.l.], v.13, p.11–14, 2006.

RIBEIRO, S. S. EXTRAÇÃO DE CARACTERÍSTICAS DE IMAGENS APLICADA À DETECÇÃO DE GRÃOS ARDIDOS DE MILHO. **Angewandte Chemie International Edition**, [S.l.], p.1–85, 2015.

ROSA, R. **Método de Classificação de Pragas por meio de Rede Neural Convolucional Profunda**. , [S.l.], p.1–92, 2018.

SHORTEN, C.; KHOSHGOFTAAR, T. M. A survey on Image Data Augmentation for Deep Learning. **Journal of Big Data**, [S.l.], 2019.

SILVA, D. S. da et al. **Recognition of Soybean Insect Pests using SURF and Template Matching**. , [S.l.], 2015.

SILVA, J. G. J. da et al. **Computer Vision and Image Processing for Detecting and Quantifying whiteflies: a systematic review**. , [S.l.], 2019.

SOUZA, W.; ALVES, A. N.; BORGES, D. L. **A Deep Learning Model for Recognition of Pest Insects in Maize Plantations**. , [S.l.], 2019.

SRIWASTWA, A. et al. Detection of Pests Using Color Based Image Segmentation. **IEEE Xplore Compliant**, [S.l.], p.4, 2018.

Stürmer, G. R. et al. Eficiência de métodos de amostragem de lagartas e de percevejos na cultura da soja. **Ciência Rural**, [S.l.], v.12, 2012.

SUJII et al. Controle de artrópodes-praga com insetos predadores *In*: Fontes e Valadares-Inglis. **Controle biológico de pragas da agricultura**. , [S.l.], 2020. Brasília, DF: Embrapa 2020 cap. 4, p. 113-140.

SZELISKI, R. **Computer Vision** : algorithms and applications. [S.l.: s.n.], 2010.

TETILA, E. C. et al. Detection and classification of soybean pests using deep learning with UAV images. **Computers and Electronics in Agriculture**, [S.l.], v.179, 2020.

TIAN, H. et al. Computer vision technology in agricultural automation —A review. **Information Processing in Agriculture**, [S.l.], v.7, p.1–19, 2020.

VOULODIMOS, A. et al. Deep Learning for Computer Vision: a brief review. **Computational Intelligence and Neuroscience**, [S.l.], v.2018, p.1–13, 2018.